Personen- und Aktivitätserkennung mittels WLAN-Signalen

Präsentation der Ausarbeitung

Anas Loukili, Yassin Ouchen

Frankfurt University of Applied Sciences

11.März 2026

Gliederung

Motivation

State of the art

Ausarbeitung der gegebenen Daten

Ausarbeitung der eigenen Datenerfassung

Fazit

References

Motivation

Motivation und Problemstellung

Ausgangslage im Gesundheits- und Sicherheitswesen:

- Kamerabasierte Systeme sind etabliert, bringen jedoch gravierende Nachteile mit sich:
  - Hohe Hardware- und Installationskosten.
  - **Privatsphäre:** Massive datenschutzrechtliche und gesellschaftliche Bedenken durch visuelle Erfassung

Der Lösungsansatz: WiFi-Sensing

- Nutzung von WLAN Channel State Information (CSI) zur kontaktlosen Aktivitätserkennung
- **Vorteil:** Wahrung der Privatsphäre (keine optischen Aufnahmen)
- **Zentrale Herausforderung:** CSI-Rohdaten sind hochgradig komplex und störanfällig. Zuverlässige Aktivitätsmuster müssen algorithmisch aus dem Rauschen extrahiert werden

Zielsetzung und Struktur der Arbeit

Übergeordnetes Ziel

Evaluierung von Deep-Learning-Methoden für die CSI-basierte Aktivitätserkennung in einem zweiteiligen Untersuchungsdesign (Labor vs. Realität).

- **Teil 1: Etablierung einer Baseline (Forschungsdatensatz)**
  - Analyse des bereitgestellten Labor-Datensatzes [2]
  - Entwicklung und Vergleich geeigneter Preprocessing- und Deep-Learning-Architekturen
- **Teil 2: Transfer in die Praxis (Eigene ESP32-Erhebung)**
  - Datenerhebung in einer realen Wohnumgebung mittels kostengünstiger ESP32-Hardware.
  - **Kritischer Vergleich:** Labor vs. Realität (Fokus auf Datenqualität, Störanfälligkeit und Übertragbarkeit der Modelle)
  - Beantwortung der Frage: Ist das Verfahren reif für günstige IoT-Hardware in realen Umgebungen?

SOTA

Aktueller Stand:

HAR & Fall Recognition (Damodaran et al., 2020) [2]

- **Hardware & Erfassung:** Einsatz von Intel IWL 5300 Netzwerkkarten zur Aufzeichnung von 802.11n WiFi-CSI-Daten in LOS- und N-LOS-Szenarien[
- **Vorverarbeitung:** Signalentrauschung mittels diskreter Wavelet-Transformation (DWT) kombiniert mit Hauptkomponentenanalyse (PCA) und spektraler Merkmalsextraktion
- **Modellarchitektur:** Vergleichende Klassifikation von Aktivitäten (inkl. Sturzerkennung) mittels Support Vector Machine (SVM) und einem LSTM-Netzwerk
- **Ergebnisse:** Präzise Unterscheidung dynamischer und statischer Posen (über 95 %), wobei die SVM mit Feature-Engineering das LSTM auf Rohdaten leicht übertraf

LSTM-Attention (Abdurrahman et al., 2025) [1]

- **Hardware & Erfassung:** Einsatz kostengünstiger ESP32-Mikrocontroller zur Aufzeichnung von WiFi-CSI-Amplitudendaten für Aktivitätsklassifizierung
- **Robuste Vorverarbeitung:** Pipeline kombiniert Hampel- und Savitzky-Golay-Filter zur Rauschunterdrückung, robustes Scaling (Median/IQR) gegen Ausreißer sowie SMOTE zur Klassenbalancierung.
- **Modellarchitektur:** Nutzung eines LSTM-Netzwerks, erweitert um einen Additive-Attention-Mechanismus
- **Ergebnisse:** Modell erreichte nach Monte-Carlo-Simulation makro-gemittelte Gesamtgenauigkeit von 95 %

Ausarbeitung der gegebenen Daten

Preprocessing I: Datenstruktur und Standardisierung

Ausgangslage: Die CSI-Rohdaten

- Daten liegen als zusammenhängende Messsessions pro Aktivität vor
- **Matrix-Format:** Jede Session besteht aus #Zeitschritten $\times$ #Subcarrier Features

Z-Transformation (StandardScaler)

- **Problem:** Subcarrier-Kanäle weisen extrem unterschiedliche Wertebereiche auf (Verzerrung des Lernprozesses)
- **Lösung:** Standardisierung der Daten auf Mittelwert $\mu = 0$ und Standardabweichung $\sigma = 1$.
- **Verhinderung von Data Leakage:**
  - Parameter (μ, σ) werden *ausschließlich* auf den Trainingsdaten berechnet.
  - Testdaten werden strikt nur mit diesen Parametern transformiert

Preprocessing I: Datenstruktur und Standardisierung

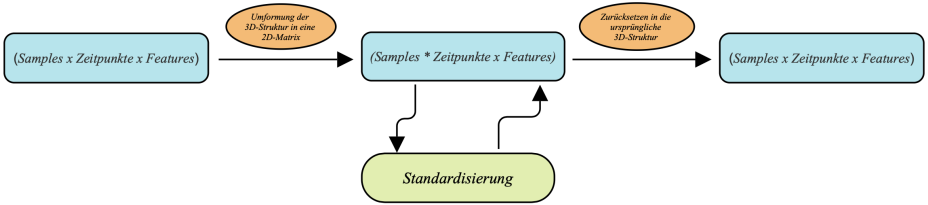

Abbildung 1: Transformierung der Struktur für Standardisierung

Preprocessing II: Data Augmentation

Zielsetzung:

- Vermeidung von Overfitting auf statische Raumcharakteristika
- Erhöhung der Modellrobustheit gegenüber Hardware-Schwankungen durch künstliche, physikalisch plausible Modifikationen

Die drei angewendeten Transformationen:

1. **Magnitude Scaling:** Multiplikation der Amplitude mit Zufallsskalaren ($s \in [0.9, 1.1]$) zur Simulation von Distanzänderungen und Pfadverlusten
2. **Time Shifting:** Verschiebung der Sequenz um bis zu 10 Zeitschritte (fördert zeitliche Invarianz, da Startpunkte stochastisch variieren)
3. **Additives Gaußsches Rauschen:** Hinzufügen eines Fehlerterms ($\sigma^2 = 0{,}0001$) zur Simulation des unvermeidbaren thermischen Hardware-Rauschens [6]

Evaluierungsstrategie: Group K-Fold Cross-Validation

Das Problem: Temporal Data Leakage

- WiFi-CSI-Zeitreihen besitzen eine extrem hohe Autokorrelation
- Benachbarte Datenfenster enthalten fast identische Umgebungs- und Rauschartefakte
- Ein klassischer Train/Test-Split führt zu massiver **Überschätzung** der Genauigkeit (Modell lernt den Raum auswendig, nicht die Aktivität)

Die Lösung: Strikt sitzungsbasierte Trennung

- Einsatz der *Group K-Fold Cross-Validation*.
- Daten einer kompletten Messsession (*Group*) landen **entweder** komplett im Trainings- **oder** im Validierungsset.
- **Ergebnis:** Das Modell wird gezwungen, auf völlig *unbekannte* Messsessions zu generalisieren – die einzig realistische Evaluationsmetrik für IoT-Systeme.

Modelle - LSTM

Layer (Type)	Output Shape	Param #
LSTM	(None, 64)	82.176
Dropout	(None, 64)	0
Dense	(None, 16)	1.040
Dense (Output)	(None, 5)	85
Total params		**249.905**
Trainable params		**83.301**
Non-trainable params		**0**
Optimizer params		**166.604**

Tabelle 1: Architektur und Parameterübersicht des LSTM-Modells

Modelle - CNN

Layer (Type)	**Output Shape**	**Param #**
Conv1D	(None, 496, 32)	40.992
BatchNormalization	(None, 496, 32)	128
MaxPooling1D	(None, 248, 32)	0
GlobalAveragePooling1D	(None, 32)	0
Dropout	(None, 32)	0
Dense	(None, 16)	528
Dense (Output)	(None, 5)	85
Total params		**125.073**
Trainable params		**41.669**
Non-trainable params		**64**
Optimizer params		**83.340**

Tabelle 2: Architektur und Parameterübersicht des 1D-CNN-Modells

Evaluation

Klasse	Prec.	Rec.	F1	Supp.
Empty	0.96	1.00	0.98	54
Lying	0.99	0.97	0.98	70
Sitting	1.00	0.94	0.97	31
Standing	0.96	0.98	0.97	44
Walking	1.00	1.00	1.00	42
Accuracy			**0.98**	**241**
Macro Avg	0.98	0.98	0.98	241
Weighted Avg	0.98	0.98	0.98	241

Tabelle 3: Klassifikationsbericht LSTM

Klasse	Prec.	Rec.	F1	Supp.
Empty	0.98	1.00	0.99	54
Lying	1.00	0.99	0.99	70
Sitting	1.00	1.00	1.00	31
Standing	1.00	1.00	1.00	44
Walking	1.00	1.00	1.00	42
Accuracy			**1.00**	**241**
Macro Avg	1.00	1.00	1.00	241
Weighted Avg	1.00	1.00	1.00	241

Tabelle 4: Klassifikationsbericht CNN

Ergebnisse

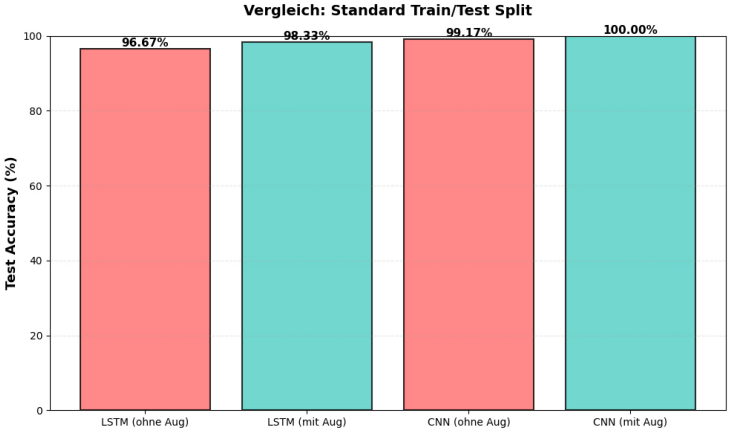

Abbildung 2: Vergleich der Train/Test Split Ergebnisse

GroupKFold

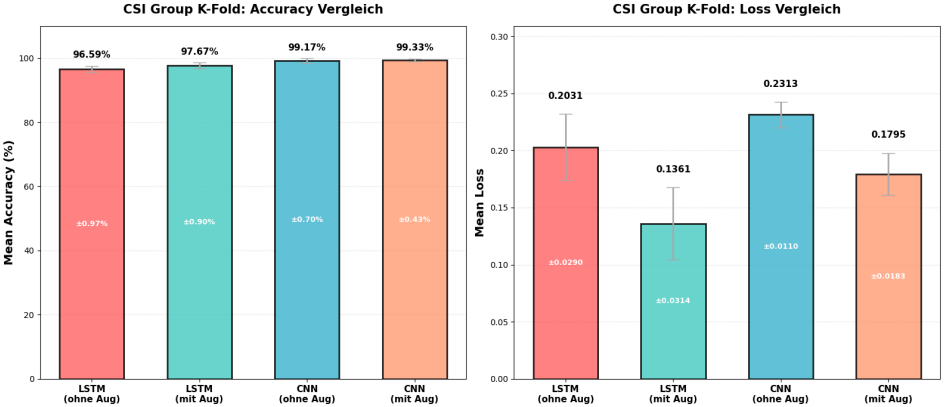

Abbildung 3: Gesamtvergleich von der GroupKFold

Ausarbeitung der eigenen Datenerfassung

Hardware-Setup & Datenerfassung

Hardware & Kommunikation

- ESP32-Setup im 20-MHz-Band
- Serielle USB-Übertragung zum Host-Rechner
- Datenerfassung via Open-Source *ESP32-CSI-Toolkit* (S. M. Hernandez)

Signalextraktion

- 64 Frequenz-Subcarrier pro Wi-Fi-Paket
- Berechnung der Amplitude aus den übermittelten Real- und Imaginärteilen

Versuchsumgebung

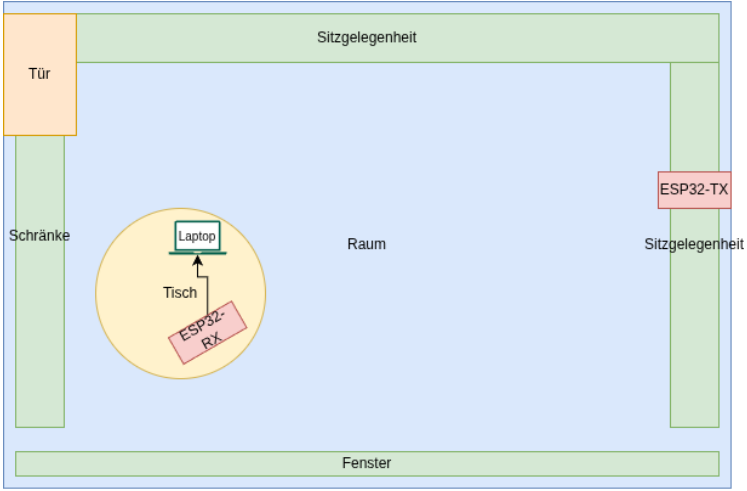

Abbildung 4: Räumliche Beschreibung des Versuchsaufbaus und der Sensorplatzierung.

Herausforderungen

Physikalische Herausforderungen

- **2,4-GHz-Interferenzen:** Überlagerung durch benachbarte Router (minimiert durch Wi-Fi-Kanal 13)
- **Multipath Propagation:** Komplexe Echos und Pfadverluste durch Reflexionen an Wänden und Möbeln
- **Räumliche Sensibilität:** Bereits minimale Hardware-Verschiebungen verändern Signalpfade drastisch
- **Temporal Shifts:** Unvorhersehbare Schwankungen in der Basischarakteristik des Signals über die Zeit

ESP32-Hardware-Limitierungen

- **Antennenleistung:** Fehlende Signalverstärker erfordern eine hochpräzise räumliche Kalibrierung
- **Grundrauschen:** Stark ausgeprägtes Rauschen erzwingt rechenintensive Glättungsverfahren
- **Hardware-Jitter:** Inkonsistente Sampling-Raten und Übertragungsfehler unter Netzwerklast
- **Problematik:** Datenlücken erschweren das exakte Befüllen fester Eingabefenster für das LSTM

- Der Einsatz in realen Wohnumgebungen kombiniert physikalische Hochfrequenz-Störungen unweigerlich mit den Leistungsgrenzen von Mikrocontrollern

Herausforderungen

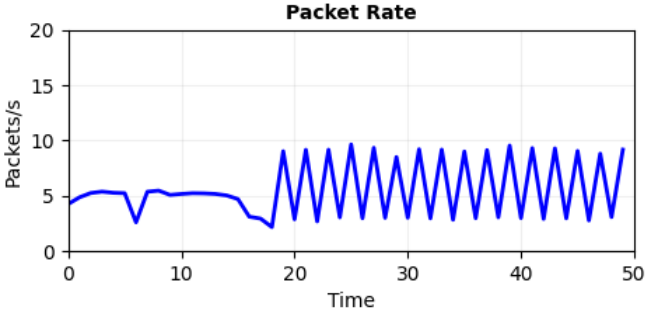

Abbildung 5: Inkonsistente Paketrate aufgrund von Umgebungsinterferenzen und Hardware-Limitierungen

Live Pipeline

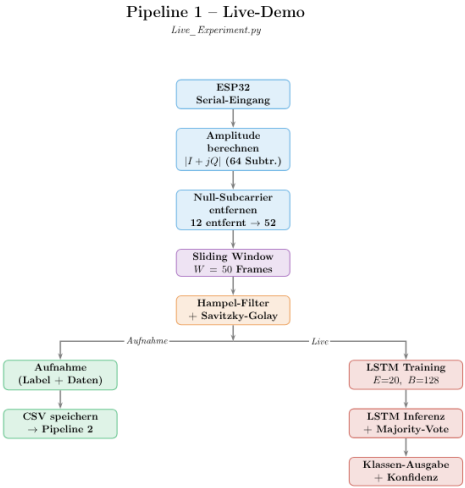

Abbildung 6: Live-Pipeline Aufbau

Offline Pipeline

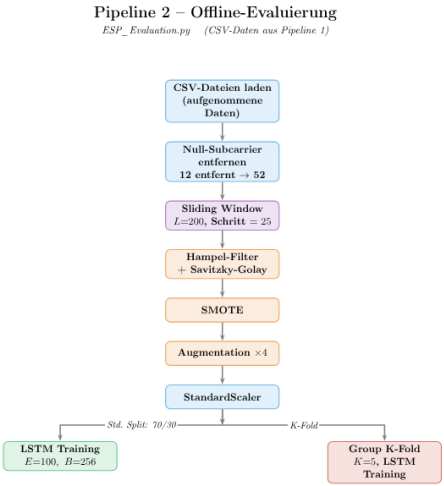

Abbildung 7: Offline-Pipeline Aufbau

Das Hybrid-Model

Layer (Type)	Output Shape	Parameter
Conv1D	(None, 195, 64)	20.032
AveragePooling1D	(None, 97, 64)	0
Dropout	(None, 97, 64)	0
LSTM	(None, 32)	12.416
Dropout	(None, 32)	0
Dense	(None, 16)	528
Dense (Output)	(None, 4)	68
Total params		**99.134**
Trainable params		**33.044**
Non-trainable params		**0**
Optimizer params		**66.090**

Tabelle 5: Architektur des CNN-LSTM-Modells

Bewertung - Accuracy + Loss

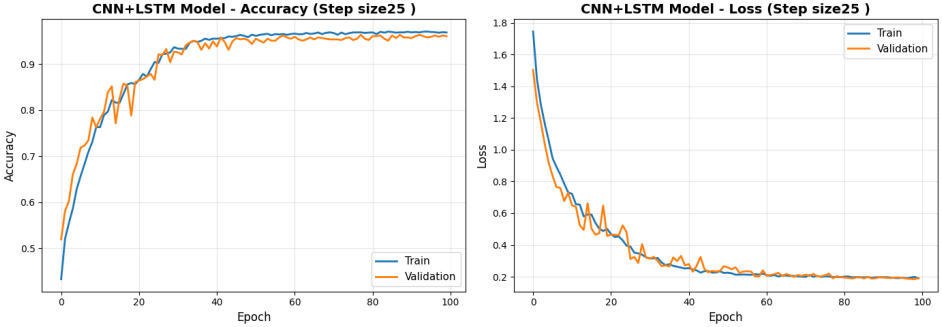

Abbildung 8: Accuracy sowie Loss des Hybriden Models beim Standard Split.

Bewertung - Validaton accuracy pro Fold

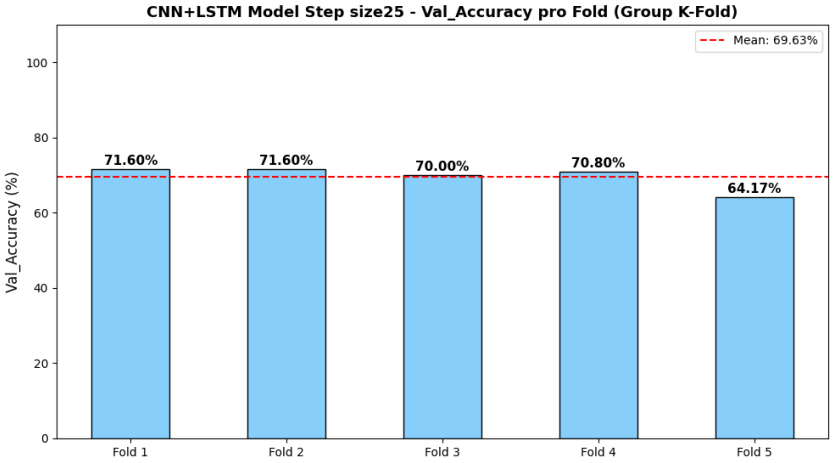

Abbildung 9: Validation Accuracy pro Fold

Vergleich der Klassifikationsberichte

Klasse	Prec.	Rec.	F1	Supp.
Empty	1.00	0.95	0.97	165
Standing	0.95	1.00	0.97	211
Walking	0.99	0.98	0.99	183
Sitting	0.99	0.99	0.99	148
Accuracy			**0.98**	**707**
Macro Avg	0.98	0.98	0.98	707
Weighted Avg	0.98	0.98	0.98	707

Tabelle 6: Standard Train/Test-Split

Klasse	Prec.	Rec.	F1	Supp.
Empty	0.94	1.00	0.97	60
Standing	0.69	0.51	0.59	80
Walking	0.55	0.74	0.63	70
Sitting	0.97	0.80	0.88	40
Accuracy			**0.74**	**250**
Macro Avg	0.79	0.76	0.77	250
Weighted Avg	0.76	0.74	0.74	250

Tabelle 7: Group K-Fold Validierung

Video der Live-Demo

Fazit

Fazit und Ausblick

1. Methodische Kernerkenntnisse

- DL-Modelle eignen sich hervorragend für CSI-basierte Aktivitätserkennung (Labordaten: bis $100\,\%$)
- **Das Data-Leakage-Problem:** Standard-Splits überschätzen die Modellleistung ($96,18\,\%$).Eine sitzungsbasierte Group K-Fold Validierung ($69,63\,\%$) ist für eine realistische Generalisierungseinschätzung zwingend erforderlich

2. Technische Evaluation

- Reine CNNs übertreffen LSTMs bei CSI-Zeitreihen; Data Augmentation verbessert beide
- Das hybride CNN-LSTM bildet den optimalen Kompromiss für verrauschte IoT-Daten
- ESP32 ist praxistauglich, aber stark limitiert (Sampling-Rate, Jitter). Eine Vorverarbeitung (Hampel + Savitzky-Golay) ist daher essenziell

3. Ausblick

- **Software:** Adaptive Zeitfenster zur Kompensation schwankender Paketraten.
- **Modelle:** Evaluierung moderner Transformer-Architekturen
- **Skalierung:** Einsatz von *Domain Adaptation* für neue Räume (ohne Retraining) sowie umfangreichere Messkampagnen (mehr Personen/Sessions)

Vielen Dank für Ihre Aufmerksamkeit!

References I

M. T. Abdurrahman and A. Irawan.
Stable human activity recognition using esp32-collected csi data with lstm-attention.
In *2025 Tenth International Conference on Informatics and Computing (ICIC)*, pages 1–6, 2025.

N. Damodaran, E. Haruni, M. Kokhkharova, et al.
Device free human activity and fall recognition using wifi channel state information (csi).
CCF Trans. Pervasive Comp. Interact., 2:1–17, 2020.

S. Aruna Deepthi, K. Deepthi, Keerthana Prakash, Korukonda Lakshmi Samhitha, and Bachu Anoohya.
Wifi-csi based human activity recognition using esp 32.
In *2025 5th IEEE International Conference on Applied Electromagnetics, Signal Processing, Communication (AESPC)*, pages 1–7, 2025.

A. Elkelany, R. Ross, and S. Mckeever.
Wifi-based human activity recognition using attention-based bilstm.
In *Artificial Intelligence and Cognitive Science*, pages 121–133, 2022.

References II

S. M. Hernandez.
Esp32-csi-tool.
GitHub repository.
Zugriff: 2. Februar 2026.

H. Kang, J. Shin, Y. Han, and J. Choi.
Human activity recognition through augmented wifi csi signals by lightweight attention-gru.
Sensors, 25(5):1547, February 2025.

M. Kotaru et al.
Spotfi: Decimeter level localization using wifi.
In *SIGCOMM '15*, pages 269–282, 2015.

M. Lee.
Gelu activation function in deep learning: A comprehensive mathematical analysis and performance.
arXiv preprint arXiv:2305.12073, 2023.

References III

S. Tan, Y. Ren, J. Yang, and Y. Chen.
Commodity wifi sensing in 10 years: Status, challenges, and opportunities.
IEEE Internet of Things Journal, 2022.
To appear.

X. Wang et al.
Deepfi: Deep learning for indoor fingerprinting using channel state information.
In *WCNC*, pages 1666–1671, 2015.

J. Xiong and K. Jamieson.
Arraytrack: A fine-grained indoor location system.
In *NSDI 13*, pages 71–84, 2013.