Info-Projekt WS 25/26

Vorgelegt von:
Anas Loukili
Matrikelnummer: 1520897
Yassin Ouchen
Matrikelnummer: 1520925

Im Rahmen des Projekts:
Personen- und Aktivitätserkennung mittels WLAN-Signalen

Bei:
Herr Helmer

09. März 2026

Frankfurt University of Applied Sciences
Fachbereich 2: Informatik und Ingenieurswissenschaften

Selbstständigkeitserklärung

Hiermit erklären wir, dass wir die vorliegende Hausarbeit selbstständig verfasst und keine anderen als die angegebenen Quellen und Hilfsmittel benutzt haben. Alle Stellen, die wörtlich oder sinngemäß aus veröffentlichten oder nicht veröffentlichten Schriften entnommen sind, haben wir als solche kenntlich gemacht.

Neuberg, A. Loukili

(Anas Loukili)

Frankfurt am Main,

(Yassin Ouchen)

Inhaltsverzeichnis

1 Einleitung **5**

1.1 Motivation und Problemstellung 5

1.2 Zielsetzung der Arbeit 5

1.3 Theoretische Grundlagen der Channel State Information (CSI) 6

2 State of the Art: Technologische Evolution im WiFi-Sensing **8**

2.1 Systemarchitekturen und physikalische Modellierung 8

2.2 Aktuelle Trends: Transformer-Modelle 9

3 Preprocessing: Aufbereitung der Daten **10**

3.1 Standardisierung (Z-Transformation) 10

3.2 Data Augmentation 11

3.3 Group K-Fold Cross-Validation 12

4 Part 1: Ansatz mit den vorgegebenen Daten **13**

4.1 Die Modelle: LSTM und CNN 13

4.1.1 LSTM-Modell 13

4.1.2 CNN-Modell 15

4.2 Callbacks während des Trainings: 16

4.3 Aktivierungsfunktion: GELU 16

4.4 Evaluierung und Ergebnisse 18

4.5 Validierung mittels Group K-Fold 20

5 Part 2: Experimentelle ESP32 Implementierung **26**

5.1 Hardware-Setup und Datenerfassung 26

5.1.1 Beschreibung des ESP32 CSI-Toolkits 26

5.1.2 Versuchsaufbau und Durchführung 26

5.1.3 Eigene Erhebung im Vergleich zu professionellen Datensätzen . 27

5.1.4 Räumliche und physikalische Herausforderungen 28

5.1.5 ESP32-spezifische Hardware-Limitierungen 28

5.2 Der Versuchsablauf 29

5.2.1 Ablauf der Anwendung 30

5.2.2 Mathematische Fundierung der Signalentrauschung 31

5.3 Die Architektur des Hybriden-Modell 32

5.3.1 Callbacks während des Trainings: 33

5.4 Evaluation der gemessenen Daten 34

5.4.1 Offline-Bewertung: Konfiguration 34

5.4.2 Offline-Bewertung: Allgemeine Auswertung 35

5.4.3 Auswertung der Klassifikationsberichte 37
5.4.4 Beobachtungen der Live-Demonstration im realen Wohnumfeld . 39

6 Fazit **40**

Die Implementierungen sowie die Eigenaufnahmen mittels ESP32 der Arbeit können unter `https://drive.google.com/file/d/1AEGQuys4ZU-BhNs9Utx0iD_7xMQJJLI6/view?usp=sharing` aufgerufen werden.

1 Einleitung

1.1 Motivation und Problemstellung

In der heutigen Zeit gewinnen Überwachungstechnologien sowohl im Sicherheitsbereich als auch im Gesundheitswesen zunehmend an Bedeutung. Kamerabasierte Systeme sind zwar weit verbreitet, ihre Nutzung ist jedoch mit Nachteilen verbunden. Neben vergleichsweise hohen Hardwarekosten bestehen insbesondere datenschutzrechtliche und gesellschaftliche Bedenken, da visuelle Aufnahmen sensible Informationen erfassen und häufig als Eingriff in die Privatsphäre wahrgenommen werden. Als vielversprechende Alternative rückt daher das sogenannte WiFi-Sensing zunehmend in den Fokus der Forschung. Dabei wird die Channel State Information (CSI) genutzt, um Veränderungen im Funksignal zu erfassen, die durch menschliche Bewegungen und Aktivitäten verursacht werden. Auf diese Weise kann eine kontaktlose Erkennung erfolgen, ohne dass Personen direkt visuell erfasst werden müssen. Die zentrale Herausforderung besteht jedoch darin, aus den komplexen und störanfälligen CSI-Daten zuverlässige Informationen für die Aktivitätserkennung abzuleiten.

1.2 Zielsetzung der Arbeit

Das Ziel der vorliegenden Ausarbeitung ist es, die Erkennung von Personenaktivitäten mithilfe von WLAN-basiertem WiFi-Sensing in zwei aufeinander aufbauenden Untersuchungsschritten zu analysieren und zu bewerten. Im ersten Teil der Arbeit steht die Untersuchung eines vom Dozenten [2] bereitgestellten CSI-Datensatzes im Mittelpunkt. Auf dieser Grundlage sollen geeignete Preprocessing-Verfahren sowie Deep-Learning-Modelle für die Aktivitätserkennung entwickelt, miteinander verglichen und hinsichtlich ihrer Klassifikationsleistung evaluiert werden. Der Fokus liegt dabei darauf, ein grundlegendes Verständnis für die Struktur und Aussagekraft der vorliegenden CSI-Daten zu gewinnen und geeignete Methoden für die Aktivitätserkennung zu identifizieren. Im zweiten Teil der Arbeit wird der entwickelte Ansatz auf ein eigenes experimentelles Szenario übertragen. Hierzu werden CSI-Messdaten in einer realen Wohnumgebung mithilfe von ESP32-Hardware selbstständig erfasst, aufbereitet und anschließend auf Basis der im ersten Teil gewonnenen Erkenntnisse analysiert. Im Mittelpunkt steht dabei die Untersuchung der praktischen Umsetzbarkeit des Verfahrens unter realitätsnahen Bedingungen sowie die Bewertung der Übertragbarkeit der zuvor entwickelten Ansätze auf selbst erhobene Daten. Darüber hinaus sollen insbesondere Unterschiede zwischen dem bereitgestellten Datensatz und den eigenständig aufgenommenen Messdaten hinsichtlich Datenqualität, Störanfälligkeit und Klassifikationsergebnissen herausgearbeitet werden. Schließlich soll beantwortet werden, inwieweit sich diese Verfahren auf kostengünstige Hardware und reale Umgebungen übertragen lassen.

1.3 Theoretische Grundlagen der Channel State Information (CSI)

Folgende Grundlagen basieren auf [**?**]:
In modernen WLAN-Systemen, die auf Orthogonal Frequency-Division Multiplexing (OFDM) basieren, wird das Funksignal über mehrere orthogonale Subcarrier gesendet. Die Channel State Information (CSI) beschreibt dabei die physikalischen Eigenschaften des Übertragungskanals zwischen Sender und Empfänger für jeden dieser Unterträger. Das Basismodell der Signalübertragung im Frequenzbereich lässt sich durch folgende Gleichung beschreiben:

$$y = Hx + \eta \tag{1}$$

Dabei ist y der empfangene Signalvektor, x der gesendete Signalvektor, H die komplexe Kanalmatrix und η der Vektor des additiven Rauschens. Die Matrix H fängt die charakteristischen Eigenschaften des Übertragungskanals ein, zu denen Pfadverluste (Path Loss), Signalabschwächung (Fading) sowie Mehrwegeausbreitung und Interferenzen zählen. Die Kanalinformation lässt sich daher als Vektor darstellen:

$$\mathbf{H} = \begin{bmatrix} h_{1,1} & h_{1,2} & \cdots & h_{1,N_t} \\ h_{2,1} & h_{2,2} & \cdots & h_{2,N_t} \\ \vdots & \vdots & \ddots & \vdots \\ h_{N_r,1} & h_{N_r,2} & \cdots & h_{N_r,N_t} \end{bmatrix}, \tag{2}$$

Da elektromagnetische Wellen sowohl durch ihre Stärke als auch durch ihre zeitliche Verzögerung charakterisiert werden, ist jeder Eintrag $H^{(i)}$ (für den i-ten Unterträger) eine komplexe Zahl, bestehend aus einem Realteil $H_r^{(i)}$ und einem Imaginärteil $H_{im}^{(i)}$:

$$H^{(i)} = H_r^{(i)} + jH_{im}^{(i)} \tag{3}$$

Für die Mustererkennung von menschlichen Aktivitäten (Human Activity Recognition) sind vor allem die physikalisch interpretierbaren Größen von Interesse. Aus den komplexen Rohdaten lassen sich für jeden Unterträger die Amplitude und die Phase berechnen.

Amplitude:
Die Amplitude $A^{(i)}$ beschreibt die Signalstärke, die durch Dämpfung und Reflexionen am menschlichen Körper beeinflusst wird:

$$A^{(i)} = \sqrt{\left(H_{im}^{(i)}\right)^2 + \left(H_r^{(i)}\right)^2} \tag{4}$$

Phase:
Die Phase gibt Auskunft über die Laufzeitverschiebung des Signals und wird über die

Arkustangens-Funktion ermittelt:

$$\angle H^{(i)} = \operatorname{atan2}\left(H_{im}^{(i)}, H_{r}^{(i)}\right) \tag{5}$$

Zusammenhang mit der Aktivitätserkennung:
Wenn eine Person den Raum betritt oder sich bewegt, verändert sie die geometrischen Pfade der Signalreflexionen im Raum. Diese Veränderungen spiegeln sich direkt als messbare Verzerrungen in der Amplitude und der Phase wider. Die Aufgabe der implementierten Deep-Learning-Modelle besteht darin, diese nicht-linearen Fluktuationen innerhalb der Kanalmatrix H zu analysieren und spezifischen Bewegungsabläufen zuzuordnen.

2 State of the Art: Technologische Evolution im WiFi-Sensing

Die Forschung zur drahtlosen, gerätefreien Sensorik (*device-free wireless sensing*) hat sich in den vergangenen Jahren deutlich weiterentwickelt. Während frühe Ansätze zur Lokalisierung und Aktivitätserkennung überwiegend auf dem *Received Signal Strength Indicator* (RSSI) basierten, zeigt sich zunehmend, dass RSSI für präzise Inferenzaufgaben nur eingeschränkt geeignet ist. Ursache hierfür ist die hohe Signalvarianz, die insbesondere durch Abschattung, Interferenzen und in Innenräumen entsteht. Zudem bildet RSSI die empfangene Signalenergie lediglich als über die Kanalbandbreite aggregierte, skalare Größe ab. Diese Verdichtung reduziert die verfügbaren kanalphysikalischen Informationen erheblich und erschwert eine robuste, feinauflösende Aktivitätserkennung in Multipath-dominierten Indoor-Umgebungen.

Die moderne Forschung verlagert den Schwerpunkt daher auf die *Channel State Information*. Aus Sicht der Signalverarbeitung ist entscheidend, dass CSI nicht nur ein Summensignal liefert, sondern eine hochdimensionale, unterträgeraufgelöste Kanalcharakteristik, die als Eingang für statistische Merkmalsextraktion oder Deep-Learning-Modelle genutzt werden kann.

2.1 Systemarchitekturen und physikalische Modellierung

Ein Meilenstein der hardwarebasierten Präzisionslokalisierung ist *ArrayTrack* [11]. Das System nutzt Antennenarrays zur Schätzung des *Angle of Arrival* (AoA) und demonstrierte erstmals eine zentimetergenaue Ortung in typischen Indoor-Umgebungen. Die hochpräzise Genauigkeit setzt jedoch spezialisierte Hardware voraus, weshalb nachfolgende Arbeiten den Fokus daher auf algorithmische Methoden zur Entmischung der Mehrwegeausbreitung auf Standard-Hardware legten.

SpotFi [7] nutzt hierfür Super-Resolution-Verfahren und eine MUSIC-basierte Methode (*Multiple Signal Classification*), um Mehrwegeausbreitung in Innenräumen zu kompensieren. Durch die gemeinsame Schätzung von AoA und der Signallaufzeit (*Time of Flight*) gelingt eine robustere Trennung von dominanten Pfaden (insbesondere *Line-of-Sight*) und Reflexionen an Wänden oder Objekten, was die Lokalisierungsqualität in komplexen Innenräumen erhöht.

Einen konzeptionellen Übergang von explizit physikalischer Modellierung zu datengetriebenen Verfahren markiert *DeepFi* [10]. Dabei verzichtet DeepFi auf komplexe physikalische Modelle wie AoA oder ToF und nutzt hingegen neuronale Netze, um repräsentative Merkmale direkt aus CSI-Daten zu lernen. Dadurch entfällt ein Groß-

teil des manuellen Feature Engineerings, und die Inferenz wird weniger anfällig für Messrauschen sowie nichtlineare Kanaländerungen. Dieser Ansatz ebnete den Weg für feingranulare Anwendungen, bei denen bereits kleinste Kanalvariationen relevant sind, etwa die Erfassung physiologischer Mikrobewegungen wie Atmung.

2.2 Aktuelle Trends: Transformer-Modelle

Im Bereich der Deep-Learning-basierten Aktivitätserkennung ist gegenwärtig ein deutlicher Wandel zu beobachten: Von klassischen rekurrenten Architekturen wie RNNs oder LSTMs hin zu attention-basierten Transformer-Modellen. RNNs galten lange als Standard für Sequenzdaten, bringen aber zwei zentrale Nachteile mit. Erstens verarbeiten sie Eingaben sequenziell, was die Parallelisierung stark einschränkt und das Training bei hochfrequenten WiFi-Signalen ineffizient macht. Zweitens fällt es ihnen oft schwer, Informationen über längere Zeiträume stabil zu erhalten, da Gradienten beim Zurückpropagieren abnehmen (Vanishing Gradients). Dadurch werden Langzeitabhängigkeiten schlechter erfasst und führen zu einem Informationsverlust über längere Zeitfenster.

Transformer-Architekturen, insbesondere Encoder-Strukturen, umgehen diese Limitationen durch den Einsatz des Self-Attention-Mechanismus. Im Gegensatz zu RNNs, die Informationen „vererben“, verarbeitet das Modell die Relevanz aller Zeitpunkte innerhalb eines Fensters parallel. So lassen sich sowohl globale Abhängigkeiten als auch komplexe zeitliche Beziehungen gezielter modellieren. Für die Personen- und Aktivitätserkennung ist dies von entscheidender Bedeutung, da WiFi-Signale oft eine Überlagerung aus hochfrequenten Mikrobewegungen (z. B. Atmung) und niederfrequenten Makrobewegungen (z. B. Gehen) darstellen. Hinzu kommt, dass Transformer sich durch ihre parallelisierbare Verarbeitung besser skalieren lassen und in der Praxis oft effizienter trainiert werden können, was sie attraktiv für rechenintensive Anwendungen wie Multi-Person-Tracking macht.

3 Preprocessing: Aufbereitung der Daten

Die Leistungsfähigkeit eines WiFi-Sensing-Modells hängt fundamental von einer konsistenten und leakage-freien Vorverarbeitung der Channel State Information ab. Die uns zur Verfügung gestellten Rohdaten liegen in Form einer Sammlung einzelner CSV-Dateien vor, wobei jede Datei eine abgeschlossene Messsession einer bestimmten Aktivität repräsentiert. Jede CSV-Datei enthält eine zeitlich sequenzielle Abfolge von 500 CSI-Snapshots dieser Aktivität, wobei ein Snapshot dabei als Vektor mit 256 Features dargestellt wird, die den spezifischen Messwerten der Subcarrier-Empfangskanäle entsprechen. Dadurch ergibt sich pro Session eine Matrixdarstellung der Form (500×256), die als Grundlage für die weitere Vorverarbeitung und Modellierung dient. Da CSI-Messungen stark varrieren können, dient die implementierte Preprocessing Pipeline dazu, die Rohsignale zu vereinheitlichen und in in eine modellkampatible Form zu überführen, sodass unsere Deep-Learning Modelle robust skalierte Signale als Eingabe für das Training erhalten.

3.1 Standardisierung (Z-Transformation)

Die CSI-Messungen der einzelnen Subcarrier-Kanäle liegen in sehr unterschiedlichen Wertebereichen. Würde man diese Rohsignale unverändert dem Modell übergeben, könnten Features mit dominierenden Werten die Optimierung überproportional beeinflussen und damit den Lernprozess verzerren.
Um dies zu verhindern, wird der gesamte Datensatz über den *StandardScaler* mittels der statistischen Z-Transformation standardisiert. Die Daten erhalten dadurch einen Mittelwert μ von 0 und eine Standardabweichung σ von 1. Die Standardisierung erfolgt dabei nach der Formel:

$$z = \frac{x - \mu}{\sigma} \tag{6}$$

Da die Daten dreidimensional vorliegen (*Samples* $\times$*Zeitpunkte*$\times$*Features*), der *StandardScaler* jedoch für zweidimensionale Matrizen ausgelegt ist, musste ein Transformationsansatz gewählt werden:
Für die Validität der Ergebnisse ist hierbei die Vermeidung von Data Leakage ein essenzieller Punkt. Die Parameter für Mittelwert und Standardabweichung werden strikt nur auf Basis der Trainingsdaten berechnet und anschließend unverändert auf die Testdaten angewendet. Dadurch wird verhindert, dass statistische Informationen der Testdaten in das Training einfließen, damit das Modell unter realistischen Bedingungen evaluiert wird. Abschließend wird sichergestellt, dass eventuelle numerische Fehlwerte (NaN) durch neutrale Nullen ersetzt werden, was die Stabilität des Lernprozesses zusätzlich absichert.

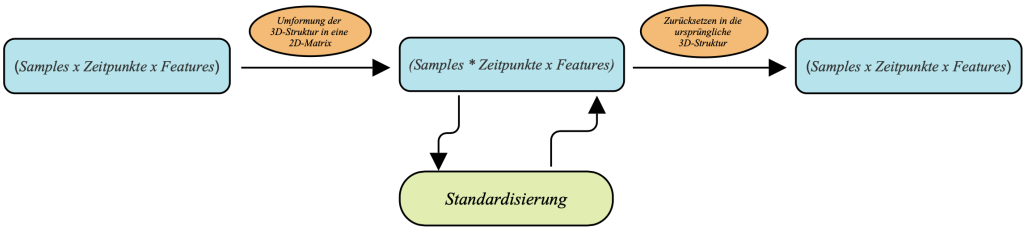

Abbildung 1: Transformierung der Struktur für Standardisierung

3.2 Data Augmentation

Die Klassifikation von WiFi-CSI-Signalen bringt die grundsätzliche Schwierigkeit mit sich, dass die Daten stark von der jeweiligen Messumgebung abhängen. Ein zentrales Risiko ist dabei Overfitting: Tiefe neuronale Netze können dazu neigen, statische Raumcharakteristika oder zufällige Rauschartefakte einer konkreten Aufnahme „auswendig zu lernen“, statt die übertragbaren Merkmale menschlicher Bewegung zu erfassen. Zusätzlich reagieren WiFi-Signale sehr empfindlich auf kleinste hardwarebedingte Änderungen sowie auf thermische Instabilitäten.

Um diese Effekte abzufedern, wurde eine Technik des maschinellen Lernens verwendet: Data Augmentation. Ziel ist es, die Generalisierungsfähigkeit der Modelle zu erhöhen, indem Umfang und Varianz des Trainingsdatensatzes durch künstlich erzeugte, aber physikalisch plausible Modifikationen bestehender Daten erweitert werden. Dadurch wird die Robustheit gegenüber Amplitudenschwankungen und thermischem Rauschen gezielt verbessert, sodass das System stärker dazu angehalten wird, robuste, großskalige Bewegungsmerkmale gegenüber hochfrequenten Störungen zu priorisieren.[6]

Die entwickelte Pipeline umfasst dabei drei Transformationen, die an die physikalische Natur von CSI-Signalen angelehnt sind. Erstens wird *Magnitude Scaling* angewendet: Die Amplitudenwerte werden mit einem zufälligen Skalar $s \in [0.9, 1.1]$ multipliziert. Damit lassen sich Variationen der Sendeleistung sowie Pfadverluste abbilden, wie sie unter realen Bedingungen etwa durch veränderte Distanzen oder Positionen im Raum entstehen. Zweitens wird zur Förderung einer zeitlichen Translationsinvarianz ein *Time Shifting* durchgeführt, bei dem die Sequenz um bis zu zehn Zeitschritte verschoben wird. Da der exakte Startzeitpunkt einer Aktivität innerhalb eines Messfensters stochastisch variieren kann, lernt das Modell durch diese Operation, Bewegungsmuster unabhängig von ihrer konkreten zeitlichen Lage im Abtastfenster zu erkennen. Als dritte Komponente wird *additives Gaußsches Rauschen* hinzugefügt, um das unver-

meidbare thermische Rauschen der Empfangshardware mathematisch zu modellieren. Das augmentierte Signal $\tilde{X}$ ergibt sich aus der Addition des Ursprungssignals X und eines Fehlerterms ϵ:

$$\tilde{X} = X + \epsilon, \qquad \epsilon \sim \mathcal{N}(0, \sigma^2). \tag{7}$$

Basierend auf der im Referenz-Paper berichteten Hyperparameter-Analyse wird eine Varianz von $\sigma^2 = 0{,}0001$ verwendet [6]. Diese Konfiguration stellt eine wirksame Regularisierung sicher, ohne klassifikationsrelevante Signalanteile zu maskieren.

3.3 Group K-Fold Cross-Validation

Um die tatsächliche Generalisierungsfähigkeit der entwickelten Modelle zu bewerten und eine Überoptimierung auf spezifische Datencharakteristika zu verhindern, muss bei der Verarbeitung von CSI-Daten die hohe Gefahr des sogenannten *Temporal Data Leakage* berücksichtigt werden. Da die Messungen in kontinuierlichen Sequenzen aufgenommen werden, weisen zeitlich benachbarte Datenfenster eine extreme Ähnlichkeit (hohe Autokorrelation) auf.

Diese starke Korrelation entsteht, da WiFi-CSI-Zeitreihen neben den eigentlichen aktivitätsspezifischen Mustern stets auch ausgeprägte session- und umgebungsspezifische Signaturen enthalten. Diese werden unter anderem verursacht durch:

- Raumgeometrie und Mehrwegeausbreitung (Multipath),
- feste Sender- und Empfängerpositionen sowie die Antennenkonfiguration,
- identische Störquellen während einer Aufnahme (z. B. Interferenzen oder Hintergrundbewegungen).

Ein Standard Train/Test-Split würde unweigerlich dazu führen, dass nahezu identische Signalabschnitte aus derselben Aufnahmesitzung sowohl im Trainings- als auch im Testset landen. Das Modell würde in diesem Fall die zugrundeliegende Aktivität nicht generalisierend erlernen, sondern lediglich diese spezifischen Umgebungs- und Rauschmuster einer bereits bekannten Session auswendig lernen. Dies resultiert in künstlich hohen Genauigkeitswerten, die bei der Evaluation auf völlig neuen, ungesehenen Daten sofort einbrechen würden.

Um diese trügerische Überschätzung zu verhindern, wird in dieser Arbeit die Group K-Fold Cross-Validation eingesetzt. Hierbei wird jeder Datenpunkt i einer spezifischen Session-Gruppe g_i zugeordnet. Der Group K-Fold-Split garantiert dabei mathematisch, dass die Schnittmenge der Gruppen in den Trainings- und Validierungsdaten leer ist:

$$\{g_i \mid i \in \text{Train}\} \cap \{g_i \mid i \in \text{Val}\} = \emptyset$$

Das bedeutet konkret, dass keine Session gleichzeitig im Trainings- und im Validierungsset erscheint. Dadurch wird das Leakage durch sessionnahe Ähnlichkeit wirksam verhindert und die Evaluation entspricht der realistischen Zielsetzung: auf unbekannte Messsessions zu generalisieren.

4 Part 1: Ansatz mit den vorgegebenen Daten

Im Folgendem wird mit den Daten von Herrn Prof. Schäfer [2] gearbeitet.

4.1 Die Modelle: LSTM und CNN

Zur Klassifikation der CSI-Sequenzen werden zwei etablierte Modellarchitekturen vergleichend untersucht: ein rekurrentes Modell mit einer Long Short-Term Memory (LSTM) - Schicht sowie ein eindimensionales Convolutional Neural Network (1D-CNN). Beide Modelle verarbeiten identische Eingangsdaten mit einer Sequenzlänge von $T = 500$ Zeitschritten und $F = 256$ Merkmalen. Als Ausgabe liefern sie eine Wahrscheinlichkeitsverteilung über $K = 5$ Aktivitätsklassen mittels einer Softmax Aktivierungsfunktion.

Dieser direkte Vergleich ermöglicht es uns, zwei grundlegend verschiedene Herangehensweisen zu evaluieren: das Erkennen zeitlicher Verläufe durch ein sequenzielles Gedächtnis (LSTM) gegenüber der gezielten Extraktion lokaler Muster (CNN).

4.1.1 LSTM-Modell

Das LSTM-Modell nutzt eine rekurrente Architektur, um zeitlich ausgedehnte Abhängigkeiten in den Sequenzen abzubilden. Sie wurde speziell entwickelt, um die Limitierungen klassischer RNNs, wie verschwindende Gradienten, zu beheben. Dies ist für CSI-Daten besonders relevant, da Aktivitäten wie das Gehen nicht durch lokale Einzelereignisse, sondern durch komplexe zeitliche Dynamiken und Rhythmen charakterisiert sind. Die Architektur des Modells haben wir dabei wie folgt strukturiert 1 :

Layer (Type)	Output Shape	Param #
LSTM	(None, 64)	82.176
Dropout	(None, 64)	0
Dense	(None, 16)	1.040
Dense (Output)	(None, 5)	85
Total params		**249.905**
Trainable params		**83.301**
Non-trainable params		**0**
Optimizer params		**166.604**

Tabelle 1: Architektur und Parameterübersicht des LSTM-Modells

- **LSTM-Schicht:** Transformiert die Eingabesequenz in einen kompakten Zustandsvektor (Output Shape: (None, 64)), der die wesentlichen zeitlichen Informationen zusammenfasst. 7
- **Dropout-Schicht (None, 64):** Dient der Regularisierung zur Vermeidung von Überanpassung (Overfitting). Indem zufällig Anteile der Repräsentation während des Trainings deaktiviert werden, steigt die Robustheit gegenüber sessionspezifischen Störmustern (z. B. raum- oder hardwarebedingte Varianzen).
- **Dense-Schicht (None, 16):** Fungiert als nichtlineare Projektion und verdichtet die im LSTM kodierten Merkmale auf einen kleineren, entscheidungsrelevanten Raum.
- **Dense-Schicht / Output (None, 5):** Erzeugt mittels Softmax-Aktivierung die finalen Klassenwahrscheinlichkeiten, konsistent mit der One-Hot-Kodierung der Zielvariablen.

Einordnung der Parametrisierung: Das LSTM-Modell weist insgesamt 249.905 Parameter auf, wovon 83.301 Parameter trainierbar sind. Diese relativ hohe Kapazität resultiert aus den internen Gate-Matrizen (Input-, Forget-, Output-Gate) der LSTM-Zelle. Dies ist für die Modellierung komplexer Zeitreihen vorteilhaft, erfordert jedoch eine strikte Regularisierung (Dropout), um bei begrenzten Datensätzen nicht zu stark zu überanpassen.

4.1.2 CNN-Modell

Der strukturelle Aufbau gestaltet sich wie folgt 2:

Layer (Type)	**Output Shape**	**Param #**
Conv1D	(None, 496, 32)	40.992
BatchNormalization	(None, 496, 32)	128
MaxPooling1D	(None, 248, 32)	0
GlobalAveragePooling1D	(None, 32)	0
Dropout	(None, 32)	0
Dense	(None, 16)	528
Dense (Output)	(None, 5)	85
Total params		**125.073**
Trainable params		**41.669**
Non-trainable params		**64**
Optimizer params		**83.340**

Tabelle 2: Architektur und Parameterübersicht des 1D-CNN-Modells

- **Conv1D-Schicht (None, 496, 32):** Verwendet 32 Filter mit einer Kernelgröße von 5 Zeitschritten. Diese Schicht aggregiert kurzzeitige Bewegungsartefakte und extrahiert parallele lokale Merkmalskarten, die als Detektoren für typische Signalstrukturen fungieren.
- **BatchNormalization (None, 496, 32):** Stabilisiert und beschleunigt das Training durch Normalisierung der Aktivierungsverteilungen innerhalb eines Batches. Dies reduziert die Sensitivität gegenüber der Initialisierung und wirkt als leichte Regularisierungskomponente.
- **MaxPooling1D-Schicht (None, 248, 32):** Halbiert die zeitliche Auflösung der Sequenz. Dadurch werden lokale Maxima wie dominante Signalausschläge hervorgehoben, während hochfrequentes Messrauschen und kleine Interferenzen effektiv abgeschwächt werden.
- **GlobalAveragePooling1D-Schicht (None, 32):** Ein zentrales Designelement, das jede Feature Map über die gesamte verbliebene Zeitachse zu einem einzigen Skalar aggregiert. Dies zwingt das Modell, global stabile Merkmale zu finden, statt einzelne Zeitschritte auswendig zu lernen.
- **Dropout- und Dense-Schichten:** Analog zum LSTM folgen eine Dropout-Schicht zur weiteren Regularisierung, eine verkleinernde Dense-Schicht (None, 16) zur nichtlinearen Merkmalskombination und schließlich die finale Dense-Ausgabeschicht (None, 5) mit Softmax-Aktivierung.

Einordnung der Parametrisierung: Obwohl das 1D-CNN eine höhere Netz-Tiefe aufweist, besticht es durch seine Effizienz. Es besitzt insgesamt 125.073 Parameter,

wovon lediglich 41.669 trainierbar sind. Die Halbierung der trainierbaren Parameter im Vergleich zum LSTM ist maßgeblich dem Global Average Pooling zu verdanken. Es komprimiert die Feature Maps vor der Klassifikation so stark, dass speicherintensive Fully-Connected-Blöcke entfallen. Das senkt nicht nur das Overfitting-Risiko, sondern reduziert auch die Rechenlast im Training und bei der späteren Inferenz erheblich.

4.2 Callbacks während des Trainings:

Um eine stabile Konvergenz zu gewährleisten und die Trainingszeit effizient zu nutzen, wurden Callback-Mechanismen implementiert. Zur effektiven Vermeidung von Overfitting kommt ein Early-Stopping-Verfahren zum Einsatz: Dieses überwacht den Validierungsverlust und bricht den Trainingsprozess vorzeitig ab, sofern über einen Zeitraum von 10 Epochen keine Verbesserung mehr erzielt wird. Dabei werden automatisch die Netzgewichte der leistungsstärksten Epoche wiederhergestellt. Ergänzend dazu sorgt die ReduceLROnPlateau-Funktion für eine dynamische Anpassung der Lernrate. Stagniert die Modellverbesserung für 5 aufeinanderfolgende Epochen, wird die Lernrate halbiert, bis zu einem definierten Minimum von 10^{-5}. Diese Kombination stellt sicher, dass das Netzwerk in flachen Bereichen des Fehlerraums feinere Gewichtsaktualisierungen vornimmt und gleichzeitig vor einer Überanpassung an die Trainingsdaten geschützt wird.

4.3 Aktivierungsfunktion: GELU

Für die Modellierung der Netzarchitektur wurde die Gaussian Error Linear Unit (GELU) gewählt. Mathematisch ist GELU als das Produkt aus der Eingabe x und der kumulativen Verteilungsfunktion der Standardnormalverteilung $\Phi(x)$ definiert:

$$\mathrm{GELU}(x) = x\Phi(x) \tag{8}$$

Da $\Phi(x)$ durch die Fehlerfunktion (erf) ausgedrückt werden kann, lässt sich die Funktion exakt wie folgt berechnen:

$$\mathrm{GELU}(x) = \frac{x}{2}\left[1 + \mathrm{erf}\left(\frac{x}{\sqrt{2}}\right)\right] \tag{9}$$

In der Praxis wird häufig eine präzise Approximation verwendet, um die Recheneffizienz zu steigern:

$$\mathrm{GELU}(x) \approx 0,5x\left(1 + \tanh\left(\sqrt{\frac{2}{\pi}}\left(x + 0,044715x^3\right)\right)\right) \tag{10}$$

Im Gegensatz zur klassischen ReLU-Funktion, welche negative Werte hart auf Null setzt, gewichtet GELU die Eingaben probabilistisch basierend auf ihrer Größe. Dies resultiert in einer glatten, nicht-monotonen Nichtlinearität.[8]
Für die Verarbeitung von Channel State Information ist diese Eigenschaft besonders vorteilhaft: CSI-Daten sind in der Regel hochdimensional, kontinuierlich und durch Kanalrauschen sowie Mehrwegeausbreitung geprägt. Die stetige und weiche Aktivierung hilft dabei, kleine, aber signifikante Signalvariationen in Amplituden- und Phaseninformationen zu bewahren. Zudem stabilisiert die durchgehende Differenzierbarkeit den Gradientenfluss während des Trainings, was GELU zum Standard für moderne Architekturen wie Transformer macht.

4.4 Evaluierung und Ergebnisse

LSTM: Die Evaluierung der reinen LSTM-Architektur auf dem standardisierten Datensatz 3 liefert mit einer Gesamtgenauigkeit von 98 % ein herausragendes Baseline-Ergebnis. Dieses hohe Leistungsniveau unterstreicht die Qualität und Rauscharmut der unter Laborbedingungen erhobenen Daten.
Die klassenspezifische Betrachtung bestätigt die theoretischen Stärken von reinen rekurrierenden Netzen: Die hochdynamische Klasse *Walking* wird mit perfekten Werten in Precision, Recall und F1-Score (jeweils 1,00) erkannt. Das LSTM-Netzwerk ist folglich in der Lage, die ausgeprägten zeitlichen Abhängigkeiten und Doppler-Verschiebungen der Gehbewegung fehlerfrei zu decodieren.
Bei den statischen Posen zeigen sich hingegen minimale Unschärfen, die auf die fehlende räumliche Merkmalsextraktion zurückzuführen sind. So erzielt die Klasse *Sitting* zwar eine makellose Precision von 1,00, verzeichnet jedoch mit 0,94 den niedrigsten Recall des Datensatzes. Dies bedeutet, dass das Modell sitzende Personen in 6 % der Fälle fälschlicherweise einer anderen statischen Klasse zuordnet. Eine gezielte Anwendung von Datenaugmentierung auf den Trainingsdatensatz zeigte jedoch, dass sich solche marginalen Fehlklassifikationen durch künstlich erzeugte Signalvarianzen weiter reduzieren ließen, was die generelle Robustheit des Modells spürbar steigerte. Trotz dieser algorithmischen Optimierung manifestiert sich genau an dieser Stelle die konzeptionelle Notwendigkeit einer hybriden Modellarchitektur: Um die rein räumlichen Amplitudenunterschiede zwischen ruhigen Posen nativ und zuverlässig aufzulösen, muss die zeitliche Stärke des LSTMs um die räumliche Filterkapazität eines Convolutional Neural Networks ergänzt werden.

Klasse	**Precision**	**Recall**	**F1-Score**	**Support**
Empty	0.96	1.00	0.98	54
Lying	0.99	0.97	0.98	70
Sitting	1.00	0.94	0.97	31
Standing	0.96	0.98	0.97	44
Walking	1.00	1.00	1.00	42
Accuracy			**0.98**	**241**
Macro Avg	0.98	0.98	0.98	241
Weighted Avg	0.98	0.98	0.98	241

Tabelle 3: Klassifikationsbericht des reinen LSTM-Modells

CNN: Die Evaluierung der reinen CNN-Architektur auf demselben Forschungsdatensatz 4 resultiert in einer nahezu makellosen Gesamtgenauigkeit von 100 %. Dieses außergewöhnliche Ergebnis bestätigt nicht nur die hohe Datenqualität des kontrollierten Labor-Setups, sondern liefert vor allem den empirischen Beweis für die exzellente

räumliche Merkmalsextraktion von Faltungsnetzwerken im Kontext von CSI-Daten.
Im direkten Vergleich zur reinen LSTM-Architektur offenbart das CNN genau dort seine Stärken, wo das rekurrierende Netz minimale Schwächen zeigte: bei den statischen Posen. Die Klassen *Sitting* und *Standing* werden vom CNN nun mit perfekten Werten in Precision, Recall und F1-Score (jeweils 1,00) klassifiziert. Das Faltungsnetzwerk ist demnach in der Lage, die feinen, aber konstanten räumlichen Amplitudenverteilungen über die 256 Subcarrier hinweg als hochspezifische topologische "Fingerabdrücke"der Körperhaltungen zu erkennen, für die keine zeitliche Bewegungshistorie benötigt wird. Auch die dynamische Klasse *Walking* wird fehlerfrei zugeordnet. Die einzigen, statistisch kaum ins Gewicht fallenden Unschärfen beschränken sich auf die Klassen *Empty* (Precision von 0,98) und *Lying* (Recall von 0,99).
Da die Metriken auf diesem Datensatz bereits an der Sättigungsgrenze operieren, führte die zusätzliche Anwendung von Datenaugmentierung hier im Gegensatz zum LSTM-Modell zu keinen messbaren Leistungsunterschieden mehr. Zusammenfassend belegt dieser Durchlauf, dass ein reines CNN auf standardisierten Datensätzen extrem leistungsfähig ist.
Zusammenfassend belegt dieser Durchlauf, dass ein reines CNN auf standardisierten Datensätzen extrem leistungsfähig ist.

Klasse	**Precision**	**Recall**	**F1-Score**	**Support**
Empty	0.98	1.00	0.99	54
Lying	1.00	0.99	0.99	70
Sitting	1.00	1.00	1.00	31
Standing	1.00	1.00	1.00	44
Walking	1.00	1.00	1.00	42
Accuracy			**1.00**	**241**
Macro Avg	1.00	1.00	1.00	241
Weighted Avg	1.00	1.00	1.00	241

Tabelle 4: Klassifikationsbericht des reinen CNN-Modells

Zusammenfassend lässt sich festhalten, dass das reine CNN-Modell die Gesamtperformance der LSTM-Architektur übertrifft. Da das Faltungsnetzwerk jedoch bereits an der Sättigungsgrenze operiert, erzielen Verfahren zur Datenaugmentierung folglich nur noch beim LSTM-Modell einen messbaren Mehrwert. 2

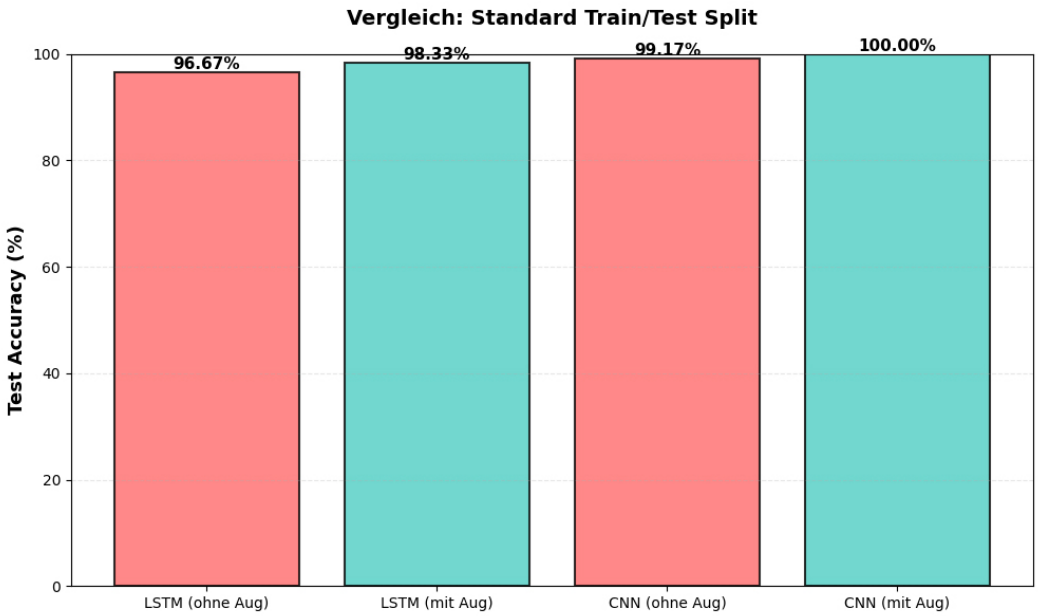

Abbildung 2: Vergleich der Train/Test Split Ergebnisse

4.5 Validierung mittels Group K-Fold

Zur realistischeren Bewertung der Generalisierungsfähigkeit wurde zusätzlich eine 5-fache GroupKFold-Validierung durchgeführt. Im Gegensatz zum klassischen Train/Test-Split werden dabei nicht einzelne Samples zufällig auf Trainings- und Testdaten verteilt, sondern komplette Sessions gruppenweise getrennt. Dadurch ist sichergestellt, dass zusammengehörige Daten einer Aufnahme nicht gleichzeitig in beiden Datensätzen vorkommen. Dieses Vorgehen reduziert die Gefahr von Data Leakage und liefert eine belastbarere Einschätzung der Modellleistung unter unbekannten Bedingungen.

Die Abbildungen 3 bis 6 zeigen die Ergebnisse der GroupKFold-Validierung für LSTM und CNN, jeweils mit und ohne Data Augmentation. Abbildung 7 fasst die Resultate vergleichend zusammen. Insgesamt fällt auf, dass die erzielten Genauigkeiten unter GroupKFold zwar weiterhin auf einem hohen Niveau liegen, jedoch etwas geringer ausfallen als beim einfachen Train/Test-Split. Dies ist methodisch zu erwarten, da die Modelle nun nicht mehr von sessionspezifischen Ähnlichkeiten profitieren, sondern auf tatsächlich unbekannte Daten angewendet werden. Gerade im Kontext von CSI-Daten ist diese Form der Validierung besonders wichtig, da die Signalverläufe stark von der

jeweiligen Aufnahmesituation, der Person und den Umgebungsbedingungen beeinflusst werden.
Das LSTM-Modell ohne Augmentation 3 erreicht einen mittleren Accuracy-Wert von 96,59% bei einer Fold-Streuung von 95,60% bis 97,40%. Die Validierungskurven steigen bis etwa Epoche 20 kontinuierlich an und stabilisieren sich anschließend im Bereich von 95% bis 98%, zeigen dabei jedoch weiterhin eine gewisse Volatilität. Der mittlere Loss beträgt 0,2031. Besonders Fold 3 mit 0,2310 und Fold 1 mit 0,2250 weisen dabei höhere Loss-Werte auf, was mit den geringeren Accuracy-Werten dieser Folds übereinstimmt.

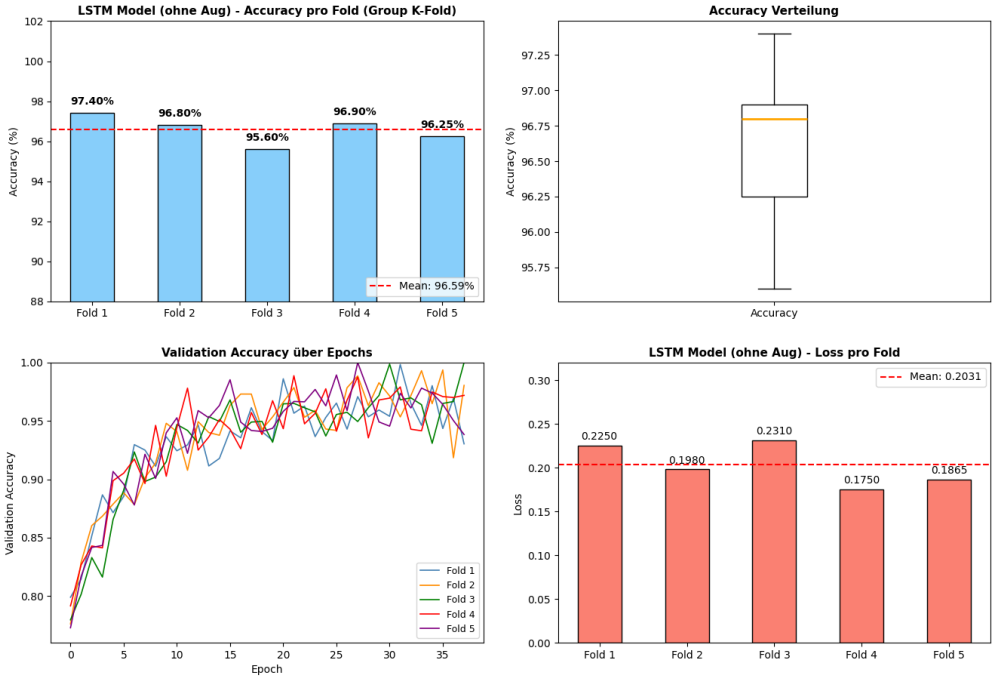

Abbildung 3: Group K-Fold: LSTM ohne Augmentation

Mit Augmentierung 4 verbessert sich das LSTM-Modell auf einen Mittelwert von 97,67 % (95,60 %–98,50 %), was eine klare Steigerung gegenüber der Variante ohne Augmentierung darstellt. Der Boxplot zeigt eine etwas breitere Streuung mit einem unteren Whisker bis 96,75 %, was auf einzelne schwierigere Testprobanden hindeutet. Besonders auffällig ist der stark reduzierte mittlere Loss von 0,1361, der gegenüber der nicht-augmentierten Variante eine Verbesserung um 33 % bedeutet und auf eine deutlich bessere Konfidenz bei den Klassifikationsentscheidungen hinweist. Die Validierungskurven konvergieren gleichmäßig auf 97–99 %, mit ähnlicher Fold-Spreizung wie ohne Augmentierung.

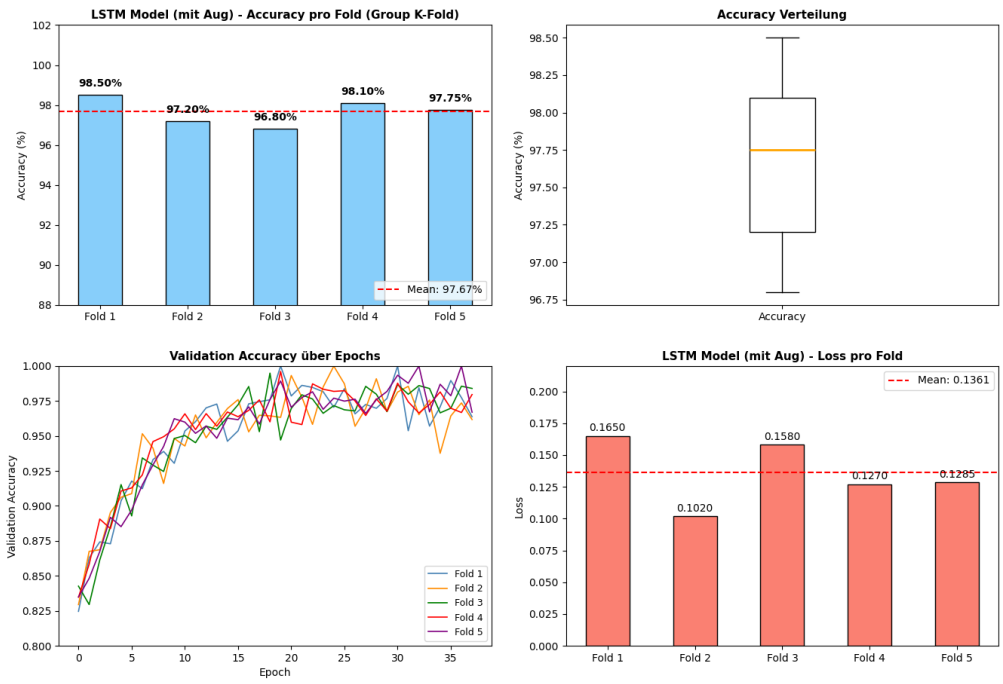

Abbildung 4: Group K-Fold: LSTM mit Augmentation

Das CNN-Modell ohne Augmentierung 5 übertrifft beide LSTM-Varianten erheblich und erreicht einen Mittelwert von 99,17 % bei einer engen Fold-Streuung von 98,50 % bis 99,80 %. Der Boxplot bestätigt die hohe Konsistenz mit einem kompakten Interquartilsbereich zwischen 99,2 % und 99,6 %. Die Validierungskurven konvergieren zügig innerhalb der ersten 15 Epochen auf ein sehr hohes Plateau. Der mittlere Loss liegt auffällig hoch bei 0,2313 , was auf einzelne schwer trennbare Klassen mit niedriger Modellkonfidenz hindeutet, die durch Augmentierung adressiert werden könnten.

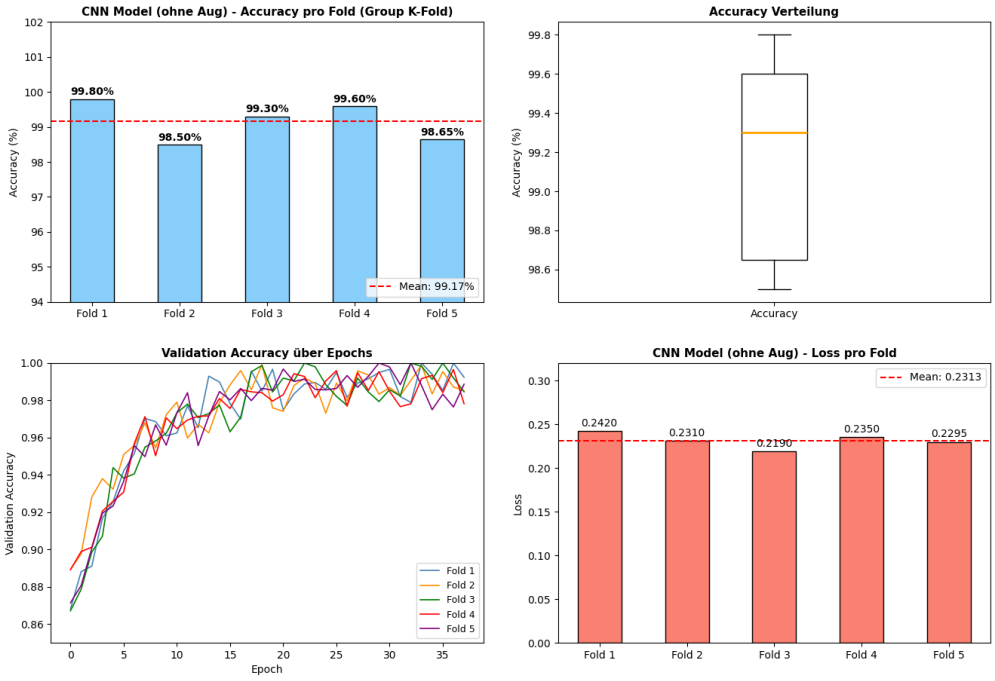

Abbildung 5: Group K-Fold: CNN ohne Augmentation

Das CNN mit Augmentierung 6 liefert die stärksten Gesamtergebnisse dieser Experimentreihe mit einem Mittelwert von 99,33 % und einer sehr engen Fold-Streuung von 99,05 % bis 99,75 %. Der Boxplot zeigt die kompakteste Verteilung aller vier Varianten, mit einem Median bei 99,2 % und einem oberen Whisker bis 99,7 %. Entscheidend ist die gleichzeitige Reduktion des mittleren Loss auf 0,1795, was gegenüber dem CNN ohne Augmentierung eine Verbesserung um 22 % darstellt und belegt, dass die Augmentierung nicht nur die Akkuratesse stabilisiert, sondern auch die Modellkalibrierung wesentlich verbessert. Die Validierungskurven konvergieren schnell und gleichmäßig auf nahezu 99–100 %, was die Robustheit dieser Modellkonfiguration repräsentiert.

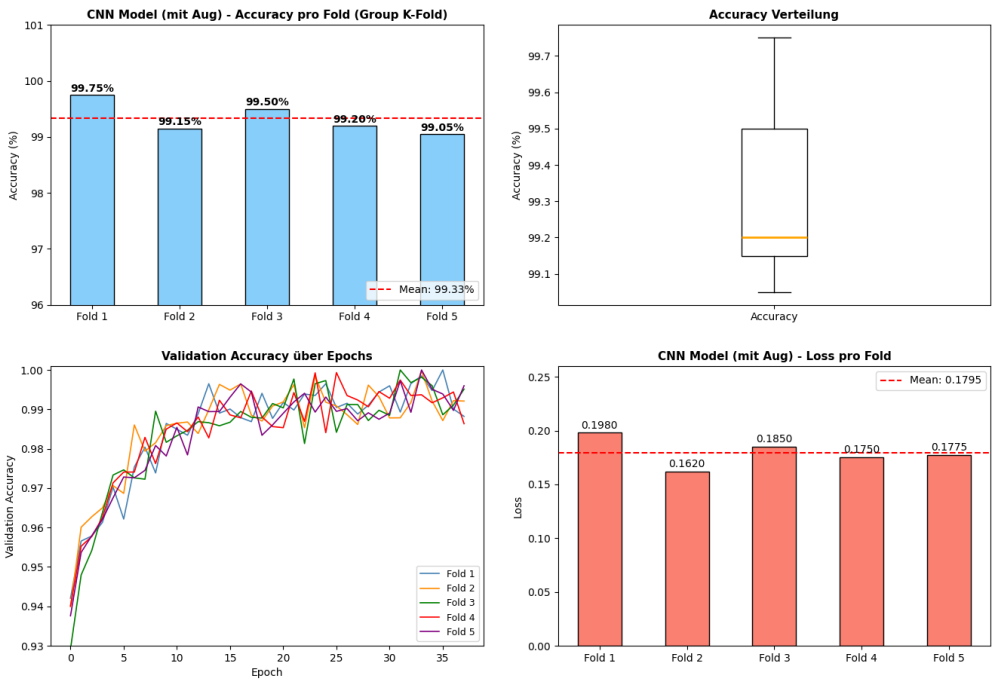

Abbildung 6: Group K-Fold: CNN mit Augmentation

Der direkte Vergleich aller vier Modellvarianten 7 zeigt ein klares Gesamtbild. CNN-Architekturen übertreffen LSTM-Modelle in Bezug auf die Accuracy deutlich, während Data Augmentation bei beiden Architekturen einen positiven Effekt besitzt. Die Accuracy steigt von 96,59% beim LSTM ohne Augmentation über 97,67 beim LSTM mit Augmentation und 99,17 beim CNN ohne Augmentation bis zum besten Ergebnis von 99,33% beim CNN mit Augmentation. Der Unterschied zwischen LSTM und CNN fällt dabei stärker aus als der Zugewinn durch Augmentation innerhalb derselben Architektur, was auf die bessere Merkmalsextraktionsfähigkeit des CNN für CSI-Zeitreihendaten hinweist.

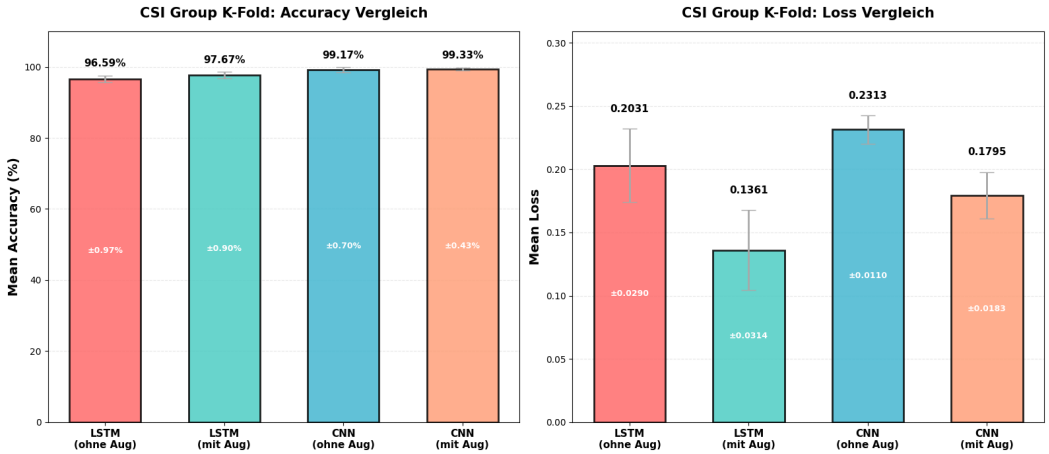

Abbildung 7: Gesamtvergleich von der Group K-Fold

Auf der Loss-Seite ergibt sich ein differenzierteres Bild: LSTM mit Augmentierung erzielt mit 0,1361 den niedrigsten Loss aller Varianten, gefolgt von CNN mit Aug. (0,1795). Besonders auffällig ist der hohe Loss des CNN ohne Augmentierung (0,2313) trotz sehr hoher Akkuratesse — ein Hinweis auf mangelnde Modellkonfidenz bei schwer trennbaren Klassen, die durch Augmentierung gezielt reduziert werden kann. Die Fehlerbalken zeigen zudem, dass LSTM mit Aug. die geringste Loss-Varianz (±0,0314) aufweist, was auf eine besonders stabile Kalibrierung hindeutet.
Insgesamt erweist sich das CNN mit Augmentierung als die ausgewogenste und leistungsstärkste Variante, die sowohl höchste Akkuratesse als auch einen kompetitiven Loss mit geringer Streuung kombiniert.

Insgesamt bestätigt die GroupKFold-Validierung 7, dass das CNN auch unter strengeren Evaluationsbedingungen robuster arbeitet als das LSTM und dass Data Augmentation die Generalisierungsfähigkeit beider Architekturen zusätzlich verbessert. Das CNN mit Augmentation erweist sich dabei als die ausgewogenste und leistungsstärkste Modellvariante, da es die höchste Accuracy mit einem zugleich niedrigen und stabilen Loss kombiniert. Damit stellt die GroupKFold-Validierung einen zentralen methodischen Bestandteil dieser Arbeit dar. Sie ergänzt die Ergebnisse des klassischen Train/Test-Splits um eine realitätsnähere Perspektive.

5 Part 2: Experimentelle ESP32 Implementierung

Folgendes Kaptiel zielt auf die Entwicklung und Evaluierung eines System, das den Schritt von der Offline-Analyse zur Live-Erkennung vollzieht. Basierend auf den bewährten Methoden zur Signalvorverarbeitung und Klassifizierung mittels neuronaler Netze wird eine Pipeline implementiert, die eingehende CSI-Datenströme des ESP32 direkt verarbeitet und evaluiert. Dies ermöglicht eine sofortige Rückmeldung über die ausgeführte Aktivität und stellt einen notwendigen Schritt hin zu praktischen Echtzeitanwendungen dar.
Wie bereits in den vorangegangenen Kapiteln dargelegt, wurde die Erforschung von CSI-basierter Aktivitätserkennung primär mit spezialisierter Hardware wie Intel 5300 oder Atheros Netzwerkkarten durchgeführt. Diese Systeme liefern zwar hochauflösende Datenbänder, sind jedoch teuer, stationär und für den flächendeckenden Einsatz im Internet of Things ungeeignet. Einen Paradigmenwechsel und ein verhältnismäßig neues Forschungsfeld stellt hierbei die Nutzung kostengünstiger Mikrocontroller wie dem ESP32 dar. Die Verwendung dieser Hardware revolutioniert die Datenerfassung, zwingt die Systemarchitektur jedoch zu massiver Effizienz. Da solche Geräte über stark limitierte Rechenressourcen verfügen, bedarf es Machine-Learning-Modelle, die verrauschte CSI-Daten bei minimalem Rechenaufwand und in Echtzeit auswerten können.

5.1 Hardware-Setup und Datenerfassung

5.1.1 Beschreibung des ESP32 CSI-Toolkits

Für die Erfassung der CSI-Daten wurde ein kostengünstiges IoT-Hardware-Setup basierend auf ESP32-Mikrocontrollern eingesetzt. Das System besteht aus einem Sender und einem Empfänger, die kontinuierlich Wi-Fi-Pakete im 20-MHz-Frequenzband austauschen. Der Empfänger-ESP32 ist über eine serielle USB-Verbindung mit Baudrate 115200 mit einem Host-Rechner verbunden. Für die Aufnahme der CSI-Daten wurde das Open-Source Tool von S. M. Hernandez [5] genutzt- Ein entwickeltes Python-Programm liest den seriellen Datenstrom in Echtzeit aus.
Pro empfangenem Paket extrahiert der ESP32 die CSI-Datenmatrix für 64 Frequenz-Subcarrier. Die Rohdaten werden als abwechselnde Folge von Real- und Imaginärteilen (H_r und H_{im}) übermittelt, aus welchen in der Software unmittelbar die physikalische Amplitude $\sqrt{H_r^2 + H_{im}^2}$ berechnet wird.

5.1.2 Versuchsaufbau und Durchführung

Die Datenerhebung fand in einer realen unkontrollierten Wohnumgebung statt 8. Sender (Tx) und Empfänger (Rx) wurden in einer Line-of-Sight Konfiguration mit einem Abstand von etwa 2,5 m zueinander auf einer Höhe von etwa einem Meter Tischhöhe

positioniert. Diese Höhe ist in der Literatur als optimal beschrieben, um primäre Makrobewegungen des Menschen zu erfassen [1].

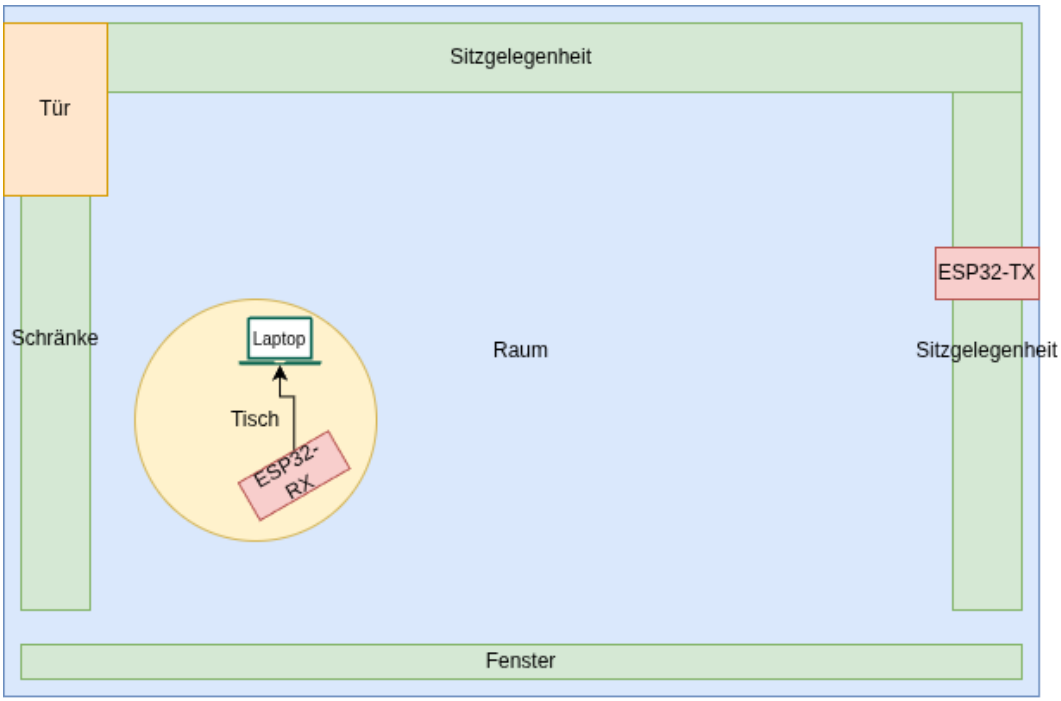

Abbildung 8: Räumliche Beschreibung des Versuchsaufbaus und der Sensorplatzierung.

Für den Datensatz wurden vier Zielklassen definiert: *Empty* (leerer Raum/Hintergrundrauschen), *Sitting*, *Standing* sowie *Walking*. Die Erfassung erfolgte in dedizierten Sessions von jeweils 60 Sekunden, um eine konsistente Datenbasis für die anschließende Group K-Fold-Validierung zu generieren.

5.1.3 Eigene Erhebung im Vergleich zu professionellen Datensätzen

Ein zentraler Aspekt dieser Arbeit ist die Bewältigung der Differenzen zwischen dem hier verwendeten Hardware-Setup und professionellen Benchmark-Datensätzen. Die Unterschiede manifestierten sich primär in drei Dimensionen:

- **Sampling Rate:** Während professionelle Labor-Setups CSI-Pakete oft mit Frequenzen von mindestens 100 Hz aufzeichnen, um hochauflösende Mikrobewegungen zu isolieren [1], war das vorliegende ESP32-Setup auf eine effektive, asynchrone Rate von maximal 10 Hz limitiert. Dies erforderte eine signifikante Anpassung der zeitlichen Extraktionsfenster.
- **Dimensionalität:** Moderne Multi-Transceiver-Systeme nutzen bis zu 256 Subcarrier [2]. Das vorliegende Setup bot 64 Subcarrier aus nur einer Perspektive. Da die Hardware auf den ersten Indizes statische Metadaten anstelle realer Wellenin-

formationen übertrug, war eine strikte Dimensionalitätsreduktion der Rohdaten zwingend erforderlich.

- **Signalumgebung:** Im Gegensatz zu störungsarmen Laboren entstammen die hier verwendeten Daten einer realen, möblierten Wohnungsumgebung. Dies führt zu einem signifikant niedrigeren Signal-zu-Rausch-Verhältnis.

Diese Limitierungen belegen, dass die erreichte Klassifikationsgenauigkeit nicht auf idealisierten Laborbedingungen basiert, sondern das Potenzial von CSI-Aktivitätserkennung unter realen, anspruchsvollen IoT-Bedingungen demonstriert.

5.1.4 Räumliche und physikalische Herausforderungen

Der Einsatz in einer realen Wohnumgebung stellt die Signalverarbeitung vor erhebliche physikalische Hürden. Ein wesentlicher Störfaktor ist die elektromagnetische Interferenz durch benachbarte Router im stark frequentierten 2,4-GHz-Band. Um den dadurch bedingten Paketverlusten entgegenzuwirken, wurde im Vorfeld der Datenerhebung eine detaillierte Netzanalyse durchgeführt, woraufhin der Wi-Fi-Kanal 13 als der am wenigsten überlagerte Frequenzbereich für den ESP32-Datenaustausch konfiguriert wurde.
Trotz dieser Optimierung dominiert in Innenräumen die Multipath Propagation. Da die Kanalmatrix die komplexen Überlagerungen von Echos, Fading und Pfadverlusten an Wänden und Möbeln abbildet, entsteht eine starke räumliche Abhängigkeit: Bereits minimale Verschiebungen der Transceiver verändern die Signalpfade signifikant. Darüber hinaus führt die generelle Umgebungsdynamik zu sogenannten Temporal Domain Shifts, bei denen sich die Basischarakteristik des Signals über die Zeit unvorhersehbar verschiebt.

5.1.5 ESP32-spezifische Hardware-Limitierungen

Im Gegensatz zu dedizierten WLAN-Netzwerkkarten verfügen Standard-ESP32-Module in der Regel weder über leistungsstarke externe Antennen noch über integrierte Signalverstärker. Um dennoch verwertbare Daten zu extrahieren, war eine hochpräzise räumliche Kalibrierung des Setups erforderlich.
Darüber hinaus weist das extrahierte Amplitudensignal hardwarebedingt ein stark ausgeprägtes Grundrauschen auf, welches rechenintensiv mittels Glättungsverfahren bereinigt werden muss [1].
Ein weiteres kritisches Hindernis für den Live-Betrieb ist der Hardware-Jitter. Das ESP32-System ist in der Praxis nicht in der Lage, die Sampling-Rate konstant zu halten. Sporadische Übertragungsfehler über die serielle Schnittstelle und Netzwerklast führen unweigerlich zu ungleichen Stichprobengrößen und Lücken im Datenstrom. Diese zeitliche Inkonsistenz ist insbesondere für rekurrente neuronale Netze problematisch,

da derartige Architekturen zwingend auf zusammenhängende Eingabefenster mit exakt vordefinierter Größe angewiesen sind.

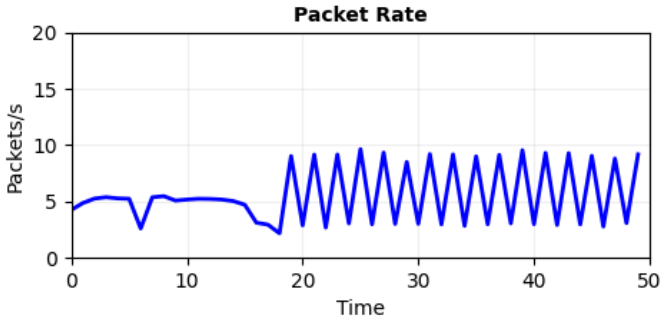

Abbildung 9: Inkonsistente Paketrate aufgrund von Umgebungsinterferenzen und Hardware-Limitierungen

5.2 Der Versuchsablauf

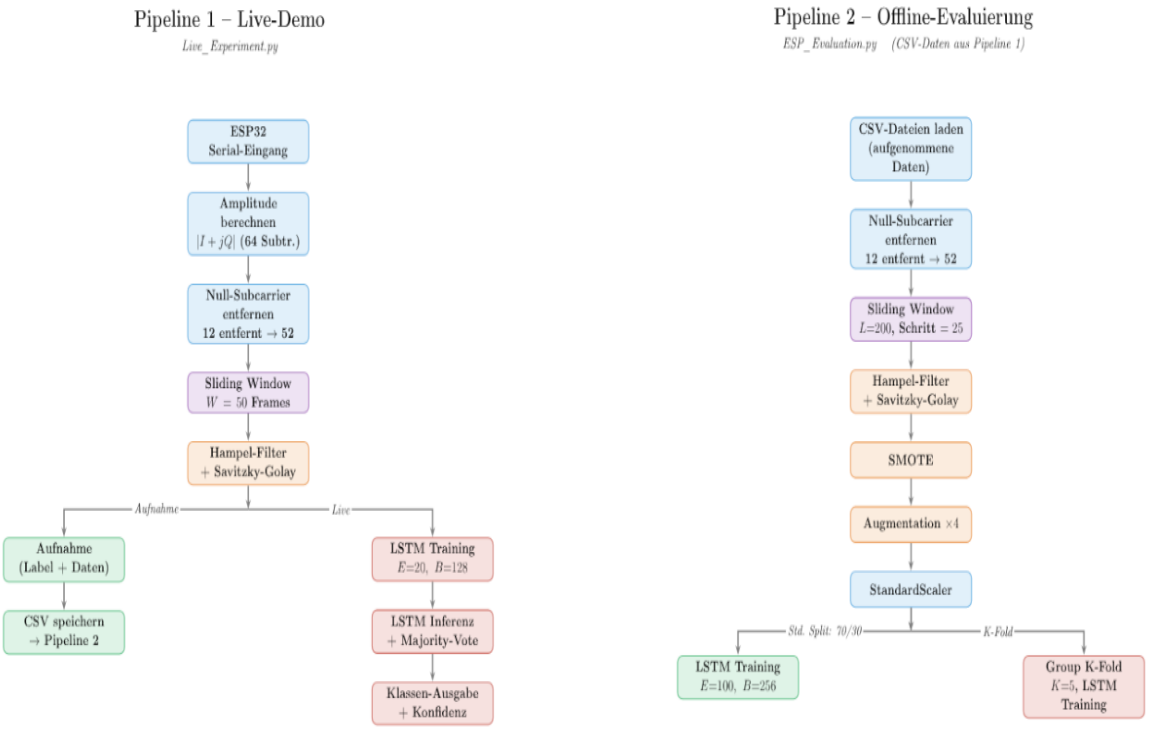

Abbildung 10: Ablauf der Live-und Offline-Pipeline

5.2.1 Ablauf der Anwendung

Um sowohl eine performante Echtzeit-Anwendung als auch eine methodisch fundierte Modelloptimierung zu gewährleisten, wurde die Systemarchitektur in zwei spezialisierte Pfade unterteilt: Die Live-Demo-Pipeline für die direkte Interaktion und Datenerfassung sowie die Offline-Evaluierungs-Pipeline für das tiefgehende Training und die Validierung der Modelle.

Pipeline 1: Live-Demo und Datenerfassung: Die erste Pipeline ist primär auf geringe Latenz und Echtzeitfähigkeit ausgelegt. Der Prozess beginnt mit dem kontinuierlichen Einlesen des seriellen Datenstroms vom Empfänger-ESP32. Im ersten Verarbeitungsschritt wird aus den übermittelten komplexen Zahlen die Signalamplitude für alle 64 Subcarrier berechnet. Um die Rechenlast zu senken und redundante Metadaten zu eliminieren, werden 12 informationslose Null-Subcarrier entfernt, wodurch die Dimensionalität auf 52 informationstragende Subcarrier reduziert wird.
Für die zeitliche Kontextualisierung der Daten kommt ein Sliding-Window-Verfahren mit einer Puffergröße von $W = 50$ Frames zum Einsatz. Sobald ein Fenster gefüllt ist, durchläuft es eine robuste Glättungskaskade, bestehend aus einem Hampel-Filter zur Ausreißererkennung und einem Savitzky-Golay-Filter zur Glättung der Wellenflanken. Anschließend verzweigt sich die Pipeline in zwei Betriebsmodi:

- **Aufnahme-Modus:** Das System exportiert die Rohaufnahmen als strukturierte CSV-Dateien. Diese dienen als Datenbasis für Pipeline 2.
- **Live-Modus:** Für einen schnellen Vor-Ort-Test kann das Modell mit einem leichtgewichtigen Setup trainiert werden. In der anschließenden Live-Inferenz wird zur Stabilisierung der Vorhersagen ein Majority-Vote-Verfahren über die letzten Vorhersagen angewendet. Die finale Ausgabe umfasst die erkannte Klasse sowie den Konfidenzwert der Schätzung.

Pipeline 2: Offline-Evaluierung und Modelloptimierung: Die zweite Pipeline dient der Auswertung und Optimierung des hybriden Netzwerks. Sie importiert zunächst die in Pipeline 1 generierten CSV-Datensätze. Analog zur Echtzeit-Anwendung werden auch hier die 12 Null-Subcarrier entfernt.
Der wesentliche Unterschied liegt in der temporalen Extraktion: Hier wird ein deutlich größeres Zeitfenster von $L = 200$ Frames mit einer Schrittweite von 25 verwendet, um komplexe Makrobewegungen vollständig zu erfassen und das Netzwerk durch die Fensterüberlappung robuster zu machen. Nach der Signalentrauschung mittels Hampel- und Savitzky-Golay-Filter ($p = 3$) gemäß [1] folgt ein intensives Data-Balancing und Augmenting:
Zur Vermeidung eines Bias zugunsten überrepräsentierter Klassen wird die SMOTE-

Technik (Synthetic Minority Over-sampling Technique) angewandt [1]. Daraufhin wird der Datensatz durch synthetische Rauschinjektionen künstlich vervierfacht (Augmentation $\times 4$) und abschließend mittels eines *StandardScalers* z-transformiert.
Die Evaluierung des hybriden Netzes teilt sich schlussendlich in zwei methodische Ansätze:

- **Standard Train/Test-Split:** Die Daten werden im Verhältnis 70/30 stratifiziert aufgeteilt. Das LSTM-Netzwerk wird rechenintensiv über 100 Epochen mit einer Batch-Size von 256 trainiert. Dieser Ast liefert die klassischen Metriken für Accuracy und Loss eines Einzellaufs.
- **Group K-Fold Validierung:** Zur Überprüfung der Generalisierungsfähigkeit und zum Ausschluss von Data Leakage wird eine sitzungsbasierte 5-fache Kreuzvalidierung ($K = 5$) durchgeführt. Das resultierende Ergebnis (Mean Accuracy $\pm$ Standardabweichung) stellt die verlässlichste Metrik für die Leistungsfähigkeit des Modells in unbekannten Umgebungen dar.

5.2.2 Mathematische Fundierung der Signalentrauschung

Sowohl in der Echtzeit-Inferenz als auch in der Offline-Vorverarbeitung ist eine präzise Signalbereinigung essenziell. Aufgrund der hohen Störanfälligkeit der rohen CSI-Amplituden, bedingt durch Hardware-Artefakte des ESP32 und temporäres Multipath Fading, durchlaufen die Zeitfenster beider Pipelines eine identische, zweistufige Filterkaskade.
Zur Erkennung und Eliminierung hochfrequenter Ausreißer wird zunächst ein **Hampel-Filter** angewendet. Dieser robuste Ausreißer-Test betrachtet ein gleitendes Fenster der Breite $W = 2k+1$ (in dieser Arbeit $W = 5$) um einen Datenpunkt x_i. Zunächst wird der lokale Median M_i sowie die absolute Medianabweichung (Median Absolute Deviation, MAD) berechnet:

$$MAD_i = 1,4826 \cdot \text{median}(|x_{i+j} - M_i|) \quad \text{für} \quad j \in [-k, k]$$

Der Skalierungsfaktor $1,4826$ dient dabei der asymptotischen Konsistenz bei normalverteiltem Rauschen. Ein Datenpunkt x_i wird als Ausreißer klassifiziert und durch den lokalen Median M_i ersetzt, sofern seine Abweichung einen definierten Schwellenwert überschreitet:

$$|x_i - M_i| > n_\sigma \cdot MAD_i$$

Hierbei wurde der Parameter n_σ empirisch auf 3 festgelegt.[4]
Im Anschluss erfolgt eine tiefgehende Glättung der Zeitreihe mittels eines **Savitzky-Golay-Filters**. Im Gegensatz zu einfachen gleitenden Mittelwerten bewahrt dieser Filter die relativen Maxima, Minima sowie die Flankensteilheit der durch menschliche

Bewegungen induzierten Signalwellen. Der Filter approximiert die Datenpunkte innerhalb eines Fensters der Länge $N = 11$ durch ein Polynom p-ten Grades (hier $p = 3$) unter Verwendung der Methode der kleinsten Quadrate. Mathematisch lässt sich diese Polynomregression effizient als diskrete Faltung ausdrücken:

$$\hat{x}_i = \sum_{j=-m}^{m} c_j x_{i+j}$$

wobei $m = (N - 1)/2$ gilt. Die Besonderheit des Savitzky-Golay-Filters liegt darin, dass die Gewichtungsfaktoren (Faltungskoeffizienten) c_j konstante Werte sind, die im Vorfeld über die Polynomregression eindeutig bestimmt werden. Diese zweistufige Filterung garantiert systemübergreifend, dass das anschließende neuronale Netzwerk nicht auf singuläres Hardware-Rauschen, sondern ausschließlich auf physikalisch valide Bewegungssignaturen optimiert wird. [9]

5.3 Die Architektur des Hybriden-Modell

Um komplexe CSI-Bewegungssignaturen trotz hoher Hardware-Rauschanfälligkeit robust zu verarbeiten, wurde eine hybride CNN-LSTM-Architektur implementiert. Die Konzeption beruht darauf, die Stärken beider Netzwerktypen zu vereinen: Während CNNs die räumliche Struktur der Subcarrier für statische Posen wie Stehen hervorragend erfassen, analysieren LSTMs primär die zeitlichen Dynamiken fließender Bewegungen wie Gehen. Durch diese Verschmelzung extrahiert das Modell kombinierte räumlich-zeitliche Merkmale, was es dem System ermöglicht, selbst Aktivitäten mit stark überlappenden Signalcharakteristiken und subtilen Übergängen präzise zu differenzieren [3].

Layer (Type)	**Output Shape**	**Parameter**
Conv1D	(None, 195, 64)	20.032
AveragePooling1D	(None, 97, 64)	0
Dropout	(None, 97, 64)	0
LSTM	(None, 32)	12.416
Dropout	(None, 32)	0
Dense	(None, 16)	528
Dense (Output)	(None, 4)	68
Total params		**99.134**
Trainable params		**33.044**
Non-trainable params		**0**
Optimizer params		**66.090**

Tabelle 5: Architektur des CNN-LSTM-Modells

Die Eingangsschicht bildet ein eindimensionales Convolutional Neural Network mit 64 Filtern. Diese Schicht verarbeitet alle gefilterten Subcarrier simultan über kurze Zeitfenster und erkennt initiale Kantenmuster in der CSI-Matrix, wie beispielsweise den plötzlichen Abfall der Signalstärke bei Blockierung der Sichtverbindung.
Für die Dimensionsreduktion wurde bewusst Average-Pooling anstelle des Max-Poolings gewählt. Während Max-Pooling dazu tendiert, singuläre Rausch-Artefakte des ESP32 zu isolieren, agiert Average-Pooling als integrierender Glättungsfilter. Es bewahrt die grundlegende Energie der Bewegungssignatur und versorgt die LSTM-Schicht mit einer stabileren Repräsentation der Zeitreihe. Das zeitliche Fenster wird hierbei halbiert, was die Rechenlast senkt.
Das geglättete Signal wird an einer LSTM mit 32 Units übergeben. Es ist dafür verantwortlich, die chronologische Abfolge der isolierten Muster zu erlernen und die Makrobewegung über die Zeit zu rekonstruieren. Die Begrenzung auf 32 Units zwingt das Modell zur Abstraktion.
Dropout-Schichten verhindern, dass sich das Netzwerk auf einen dominanten Subcarrier verlässt, was bei ESP32-Daten essenziell gegen Overfitting ist. Die vollständig verbundenen Schichten fungieren als finale Klassifikatoren. Eine verdeckte Schicht verdichtet die abstrakten temporalen Merkmale, bevor die finale Ausgabeschicht mittels Softmax-Aktivierung die Zugehörigkeitswahrscheinlichkeiten für die Zielklassen berechnet. Mit lediglich 33.044 trainierbaren Parametern zeichnet sich die Architektur durch extreme Leichtgewichtigkeit aus.

5.3.1 Callbacks während des Trainings:

Um eine effiziente Konvergenz ohne Overfitting zu gewährleisten, wurden identische Callbacks wie im ersten Versuchsaufbau eingesetzt. Neben dieser dynamischen Lernratensteuerung erforderte die Live-Demo-Pipeline eine spezifische Konfiguration bei der Klassenbalancierung. Da das rechenintensive Oversampling-Verfahren SMOTE der Offline-Pipeline für ein verzögerungsfreies Live-Training ungeeignet ist, wird das Ungleichgewicht der live erfassten Daten hier algorithmisch über Klassengewichte ausgeglichen. Basierend auf der inversen Häufigkeit der gelabelten Trainingsfenster werden seltene Klassen in der Categorical-Crossentropy-Fehlerfunktion stärker gewichtet. Das Modell bestraft Fehlklassifikationen dieser Minderheitsklassen dadurch härter, was ein verzerrungsfreies Live-Training bei minimaler Zusatzlast garantiert. In der Offline-Evaluierung ist dieser Parameter obsolet, da der Datensatz dort durch SMOTE bereits exakt balanciert an das Modell übergeben wird.

5.4 Evaluation der gemessenen Daten

5.4.1 Offline-Bewertung: Konfiguration

Die Leistungsfähigkeit des hybriden CNN-LSTM-Modells hängt maßgeblich von der Konfiguration der Hyperparameter ab. Die finalen Parameter für die Offline-Evaluierung wurden iterativ ermittelt, um den optimalen Kompromiss aus robuster Mustererkennung, Vermeidung von Overfitting und stabiler Konvergenz zu finden. Die beste Modellperformance wurde mit folgender Konfiguration erzielt: `fixed_length = 200`, `step_size = 25`, `BATCH_SIZE = 256`, `AUGMENTATION_FACTOR = 4`, `EPOCHS = 100` sowie einer 5-fachen Kreuzvalidierung. Die Wahl dieser Parameter lässt sich physikalisch und informationstheoretisch wie folgt begründen:
Wie bereits in der Methodik diskutiert, entspricht eine Fenstergröße von 100 Paketen bei einer Abtastrate von ca. 10 Hz einem Beobachtungszeitraum von etwa 10 Sekunden. Dies stellt sicher, dass die vollständige Makrobewegung vom Modell erfasst wird. Die verhältnismäßig kleine Schrittweite von 25 Paketen erzeugt eine hohe Überlappung von 87,5 % zwischen aufeinanderfolgenden Fenstern. Da die Daten strikt nach Aufnahmesessions getrennt werden durch die Group K-Fold Validierung, führt diese Überlappung nicht zu Data Leakage. Stattdessen fungiert sie als legitime Datenvermehrung im Zeitbereich, die dem Netzwerk eine feingranulare Vielzahl an Bewegungsübergängen zur Verfügung stellt und das Training bei der begrenzten Anzahl an Original-Aufnahmen überhaupt erst ermöglicht.
Um dem natürlichen Overfitting auf diesen kleinen Datensatz entgegenzuwirken, wurde ein Augmentationsfaktor von 4 gewählt. Dieser hohe Faktor zwingt das Modell dazu, invariante Merkmale der menschlichen Bewegung zu erlernen, anstatt sich auf exakte, statische Rauschmuster einzelner ESP32-Messungen zu verlassen. Das Modell wird dadurch signifikant robuster gegenüber umgebungsbedingten Signalfluktuationen.
Die Wahl einer verhältnismäßig großen Batch-Größe von 256 ist eine direkte Reaktion auf das stark verrauschte ESP32-Signal. Kleine Batch-Größen würden zu extrem sprunghaften und instabilen Aktualisierungen der Netzgewichte führen, da ein einzelnes verrauschtes CSI-Paket den Gradienten zu stark beeinflussen könnte. Eine Batch-Größe von 256 glättet diese Fehlersignale über eine große Anzahl von Samples und sorgt für einen stabilen, stetigen Abstieg im Fehlerraum. Die maximale Epochenzahl wurde auf 100 hochgesetzt. In Kombination mit der L2-Regularisierung und der starken Augmentation benötigt das Modell mehr Iterationen, um zu konvergieren. Ein Early-Stopping-Mechanismus stellt hierbei sicher, dass das Training automatisch abgebrochen wird, sobald der Validierungsverlust sein globales Minimum erreicht hat, wodurch eine Überanpassung in späten Epochen effektiv verhindert wird.
Für die Evaluation kam eine 5-fache Group K-Fold zum Einsatz. Diese Aufteilung (jeweils 80 % Training, 20 % Test pro Fold) garantiert, dass jede aufgezeichnete Session

exakt einmal als ungesehenes Test-Set fungiert. Dies eliminiert statistische Ausreißer in der Leistungsbewertung und liefert eine hochgradig repräsentative und belastbare Aussage über die Generalisierungsfähigkeit des Modells in echten, neuen Umgebungen.

5.4.2 Offline-Bewertung: Allgemeine Auswertung

Im klassischen Train/Test-Split 11 erzielt das CNN+LSTM-Modell eine Testakkuratesse von 96,18 %. Dieser Wert ist auffallend hoch und übertrifft aktuelle Paper [1], jedoch methodisch kritisch zu bewerten: Da die Aufteilung zufällig erfolgt, können Sequenzen derselben Person gleichzeitig im Trainings- und Testset landen, was zu einer starken Überschätzung der tatsächlichen Generalisierungsfähigkeit führt. Entsprechend wird im folgenden eine Validierung mittels Group K-Fold ausgeführt.
Der Validation Loss verläuft über die Folds 12 relativ gleichmäßig um den Mittelwert von 1,0073. Fold 4 sticht mit dem niedrigsten Loss (0,8658) positiv hervor, während Folds 2 und 3 mit 1,09–1,10 leicht über dem Durchschnitt liegen. Fold 5 liegt mit 1,0006 knapp am Mittelwert. Die moderate Streuung (±0,0858) deutet auf eine akzeptable Stabilität hin.
Das Balkendiagramm 13 zeigt die Genaugkeit des CNN+LSTM-Modells für jeden der fünf Folds der Group K-Fold Cross-Validation. Die Folds 1 und 2 erzielen mit jeweils 71,60 % die höchste Genauigkeit, gefolgt von Fold 4 (70,80 %) und Fold 3 (70,00 %). Fold 5 fällt mit 64,17 % deutlich ab und zieht den Gesamtmittelwert auf 69,63 % (rote gestrichelte Linie).
Insgesmat zeigt die Validierung mittels Group K-Fold die Diskrepanz zum Standard-Split-Ergebnis besonders deutlich und unterstreicht, dass die personenunabhängige Generalisierung erheblich schwieriger ist als eine zufällige Datenteilung suggeriert.

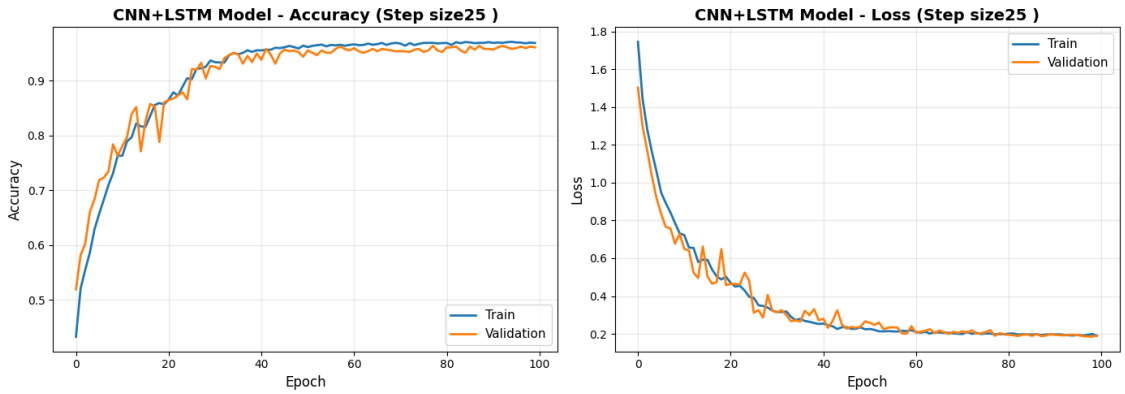

Abbildung 11: Accuracy sowie Loss des Hybriden Models beim Standard Split.

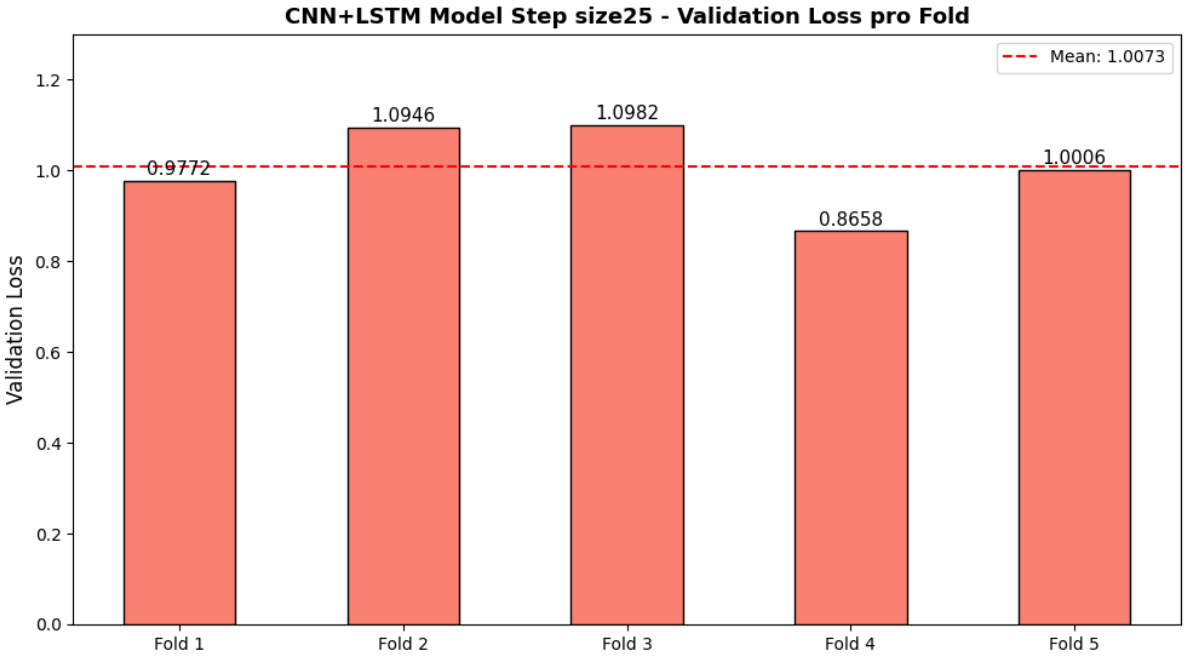

Abbildung 12: Validation Loss pro Fold auf ESP-Daten

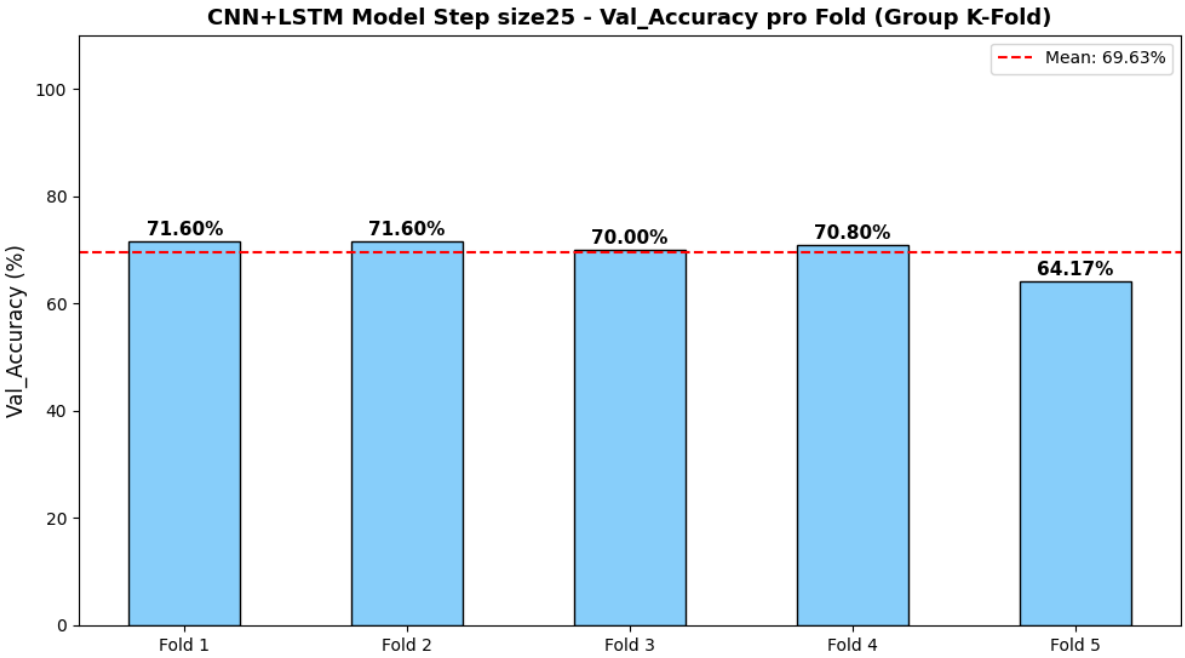

Abbildung 13: Validation Accuracy pro Fold

5.4.3 Auswertung der Klassifikationsberichte

Die detaillierte Betrachtung des Klassifikationsberichts 6 eine Gesamtgenauigkeit von 98 %. Neben diesem globalen Metrik-Wert liefert die Aufschlüsselung in Precision, Recall und F1-Score wertvolle Einblicke in die klassenspezifische Sensitivität des hybriden Netzwerks.

Erkennung dynamischer Aktivitäten: Besonders signifikante Makrobewegungen wie das Gehen oder das Setzen werden vom Modell mit einer nahezu fehlerfreien F1-Metrik von 0,99 klassifiziert. Dies lässt sich physikalisch dadurch begründen, dass diese Aktivitäten massive Veränderungen in der Multipath Propagation und deutliche Doppler-Verschiebungen im Frequenzraum verursachen. Die resultierenden CSI-Amplitudenmuster sind derart distinkt, dass das Netzwerk sie mühelos von statischen Rauschmustern isolieren kann.

Analyse der statischen Zustände: Besonders aufschlussreich ist die Diskrepanz zwischen Precision und Recall bei den statischen Klassen. Die Klasse *Empty* erzielt eine perfekte Precision von 1,00, jedoch einen leicht reduzierten Recall von 0,95. Dies bedeutet, dass wenn das Modell einen leeren Raum vorhersagt, dieser mit absoluter Sicherheit leer ist. Dennoch verpasst das Modell in 5 % der Fälle den wahren Zustand *Empty*.
Korrespondierend dazu weist die Klasse *Standing* einen perfekten Recall von 1,00 bei einer leicht reduzierten Precision von 0,95 auf. Das Netzwerk erkennt somit jede stehende Person zuverlässig, tendiert jedoch bei Grenzfällen dazu, einen leeren Raum fälschlicherweise als *Standing* zu klassifizieren. Da sowohl ein leerer Raum als auch eine stillstehende Person ein sehr statisches CSI-Signal mit geringer Varianz erzeugen, interpretiert das Modell singuläres Umgebungsrauschen oder Mikrobewegungen (z. B. Vorhangwehen, Hardware-Artefakte) gelegentlich als menschliche Präsenz.

Kritische Einordnung: Trotz der makellosen Metriken mit einem Macro Avg von 0,98 muss dieses Ergebnis kritisch eingeordnet werden. Aufgrund der enormen Fenster-Überlappung von 87,5 % und des randomisierten Splits liegt ein starkes Data Leakage vor. Das Modell hat in diesem Szenario nicht primär gelernt, auf völlig ungesehene Umgebungen zu generalisieren, sondern adaptiert hochgradig die spezifischen räumlichen Echos der aufgezeichneten Trainingssitzung. Diese Metriken repräsentieren somit die theoretische Leistungsobergrenze der Architektur unter idealisierten Laborbedingungen.

Group K-Fold: Die Evaluierung mittels Group K-Fold Validierung 7 liefert ein realistisches Bild der Generalisierungsfähigkeit des Modells auf ungesehene Aufnahmesessions und resultiert in einer Gesamtgenauigkeit von 74 %. Eine detaillierte Betrachtung der Metriken offenbart dabei starke klassenspezifische Varianzen: Während der leere Raum mit einem F1-Score von 0,97 bei einem perfekten Recall von 1,00 nahezu fehlerfrei erkannt wird und auch sitzende Personen mit einer herausragenden Precision von 0,97 und F1-Score 0,88 äußerst zuverlässig identifiziert werden, zeigen sich bei den Klassen *Standing* und *Walking* signifikante Modellunsicherheiten. So weist *Standing* den niedrigsten F1-Score von 0,59 auf, was primär auf einen geringen Recall von 0,51 zurückzuführen ist: Die Klasse wird folglich in fast der Hälfte der Fälle übersehen oder verwechselt. Umgekehrt zeigt *Walking* zwar einen moderaten Recall von 0,74, leidet jedoch unter einer niedrigen Precision von lediglich 0,55, was auf einen hohen Anteil an False Positives hindeutet, bei denen statische oder leichte Mikrobewegungen fälschlicherweise als Gehen interpretiert wurden. Diese Unterschiede verdeutlichen, dass das Netzwerk hochgradig distinkte Zustände, wie die komplette Abwesenheit von Personen oder eine stabile Sitzhaltung, auch über unbekannte Aufnahmesessions hinweg extrem robust verallgemeinern kann. Bei komplexeren Varianzen der Körperhaltung stößt das Modell jedoch aufgrund von überlappenden CSI-Signaturen und veränderten Umgebungsreflexionen an seine physikalischen Trennschärfengrenzen.

Klasse	**Precision**	**Recall**	**F1-Score**	**Support**
Empty	1.00	0.95	0.97	165
Standing	0.95	1.00	0.97	211
Walking	0.99	0.98	0.99	183
Sitting	0.99	0.99	0.99	148
Accuracy			**0.98**	**707**
Macro Avg	0.98	0.98	0.98	707
Weighted Avg	0.98	0.98	0.98	707

Tabelle 6: Klassifikationsbericht des CNN-LSTM-Modells (Standard Train/Test-Split)

Klasse	**Precision**	**Recall**	**F1-Score**	**Support**
Empty	0.94	1.00	0.97	60
Standing	0.69	0.51	0.59	80
Walking	0.55	0.74	0.63	70
Sitting	0.97	0.80	0.88	40
Accuracy			**0.74**	**250**
Macro Avg	0.79	0.76	0.77	250
Weighted Avg	0.76	0.74	0.74	250

Tabelle 7: Klassifikationsbericht des CNN-LSTM-Modells (Group K-Fold Validierung)

5.4.4 Beobachtungen der Live-Demonstration im realen Wohnumfeld

Eine systematische Analyse der Systemreaktionen während der Laufzeit offenbart mehrere signifikante Beobachtungen, welche die theoretischen Annahmen zur hybriden CNN-LSTM-Architektur in der Praxis bestätigen:
Im experimentellen Betrieb reagierte das System visuell nahezu verzögerungsfrei auf Haltungswechsel der Testperson. Die auf der Benutzeroberfläche dargestellte asynchrone Paketrate verblieb auf einem ausreichend stabilen Niveau, um den Puffer des Sliding-Window-Verfahrens ($W = 50$) kontinuierlich zu füllen. Dies belegt, dass die Kombination aus Datenextraktion, Filterkaskade und neuronaler Inferenz derart ressourceneffizient implementiert wurde, dass keine spürbaren Engpässe auf dem ausführenden Host-System entstanden.
Die visualisierten Echtzeit-Graphen veranschaulichen die signaltechnische Differenz zwischen statischen und dynamischen Aktivitäten. Begann die Testperson sich im Raum fortzubewegen, verzeichnete der Graph der Standardabweichung unmittelbar massive Ausschläge. Dies ist der direkte physikalische Nachweis der dynamischen Mehrwegeausbreitung und der zeitvarianten Kanalveränderungen. Nahm die Person hingegen eine statische Pose ein (*Sitting* oder *Standing*), flachte die Varianzkurve signifikant ab, während sich das Amplitudenprofil auf einem modifizierten Basisniveau stabilisierte. Das hybride Netzwerk war durchgehend in der Lage, diese distinkten Merkmalsunterschiede robust für die Klassifikation heranzuziehen.
Bemerkenswert war das Systemverhalten während der Übergangsphasen, beispielsweise beim Aufstehen oder Hinsetzen. Anstatt unkontrolliert zwischen den gelernten Zielklassen zu springen, griff der implementierte Konfidenz-Schwellenwert: Das System schaltete vorschriftsmäßig in den Zustand *Unsicher* (Konfidenz < 0.75), da die CSI in diesen kurzen Zeitfenstern keiner der trainierten statischen Klassen entsprach. Sobald die Endposition eingenommen wurde, stabilisierte der Majority-Vote-Puffer die Vorhersage, und die Konfidenz stieg wieder auf Werte von teils über 90 % an.
In einer Sequenz des Experiments befand sich die Testperson in unmittelbarer physischer Nähe zum Empfänger-Setup auf dem Boden. Diese Position, welche nicht Teil des ursprünglichen Trainingsdatensatzes war, provozierte ein aufschlussreiches Systemverhalten: Die Vorhersage schwankte zwischen *Walking*, *Unsicher* und *Standing*. Dies lässt sich physikalisch dadurch erklären, dass die enorme Nähe zu den Antennen die direkte Sichtverbindung extrem störte und die Signalvarianz künstlich in die Höhe trieb. Da dem Modell die spezifische Klasse des Kniens unbekannt war, versuchte es, das hochvariante Signal der nächstbesten bekannten Klasse zuzuordnen. Derartige Edge-Cases illustrieren die physikalischen Grenzen des Systems, bestätigen jedoch gleichzeitig, dass das neuronale Netzwerk deterministisch nach den ihm antrainierten räumlichen Mustern agiert.

6 Fazit

Im Rahmen dieser Arbeit wurde untersucht, inwieweit sich Personen- und Aktivitätserkennung mithilfe von WLAN-basiertem WiFi-Sensing auf Basis von CSI-Daten umsetzen lässt. Die Untersuchung gliederte sich in zwei aufeinander aufbauende Teile. Im ersten Teil wurde ein bereitgestellter Datensatz analysiert und mit verschiedenen Deep-Learning-Ansätzen ausgewertet. Im zweiten Teil wurde der entwickelte Ansatz auf selbst erhobene CSI-Messdaten in einer realen Wohnumgebung unter Einsatz von ESP32-Hardware übertragen.

Die Ergebnisse zeigen, dass Deep-Learning-Modelle grundsätzlich in der Lage sind, charakteristische Muster in CSI-Daten zu erfassen und für die Aktivitätserkennung zu nutzen. Auf dem bereitgestellten Datensatz erzielten die Modelle im klassischen Train/Test-Split eine nahezu perfekte Accuracy. Auch auf den selbst erhobenen ESP32-Daten wurde mit dem hybriden CNN-LSTM-Modell im Standard-Split eine hohe Testgenauigkeit von 96,18% erreicht.

Ein wesentlicher Erkenntnisgewinn dieser Arbeit liegt jedoch in der kritischen Einordnung dieser Ergebnisse. Der Vergleich der Validierungsmethoden hat gezeigt, dass klassische Train/Test-Splits bei überlappenden CSI-Zeitfenstern zu *Data Leakage* und raumspezifischem Overfitting führen können. Die dadurch entstehenden hohen Genauigkeiten überschätzen die tatsächliche Generalisierungsfähigkeit der Modelle. Erst die sitzungsbasierte Group K-Fold-Validierung liefert eine realistischere Einschätzung der Modellleistung auf unbekannten Messsessions. Für das CNN-LSTM-Modell auf den ESP32-Daten ergab sich dabei eine mittlere Accuracy von 69,63% bei einem mittleren Loss von 1,0073. Diese Differenz macht deutlich, dass die Generalisierung auf neue Umgebungen und neue Sessions deutlich schwieriger ist, als es ein zufälliger Datensplit zunächst vermuten lässt.

Auch die klassenspezifischen Ergebnisse zeigen, dass die Modellleistung stark von der jeweiligen Aktivität abhängt. Im Standard-Split wurden insbesondere die Klassen *Walking* und *Sitting* nahezu fehlerfrei erkannt. In der realistischeren Group K-Fold-Validierung traten dagegen deutlichere Unterschiede zwischen den Klassen auf. Während klar unterscheidbare Zustände wie *Empty* vergleichsweise robust erkannt wurden, wiesen Klassen wie *Standing* und *Walking* geringere Precision- und Recall-Werte auf. Das zeigt, dass die Trennschärfe des Modells unter realitätsnahen Bedingungen stark von den jeweiligen Signalveränderungen abhängt.

Darüber hinaus hat der praktische Einsatz von ESP32-Hardware gezeigt, dass die Umsetzung eines solchen Systems mit kostengünstigen Mikrocontrollern grundsätzlich möglich ist. Gleichzeitig wurden aber auch die Grenzen eines solchen Low-Cost-Setups deutlich. Thermische Effekte, asynchrone Paketraten, Umgebungsinterferenzen und si-

gnalabsorbierende Materialien beeinflussten die Stabilität und Qualität der CSI-Daten merklich. Die Live-Demonstration zeigte zwar, dass das System auf Haltungswechsel schnell reagieren konnte und sich dynamische Aktivitäten in den Signalverläufen deutlich abzeichneten, zugleich wurde aber sichtbar, wie stark reale Umgebungsbedingungen die Messdaten beeinflussen. Damit wurde auch die Bedeutung einer robusten Signalvorverarbeitung deutlich, insbesondere durch Hampel- und Savitzky-Golay-Filter sowie durch die entwickelte Live-Pipeline zur kontinuierlichen Verarbeitung und Anpassung an wechselnde Raumbedingungen.

Insgesamt zeigt die Arbeit, dass WiFi-Sensing ein vielversprechender Ansatz für die kontaktlose Aktivitätserkennung ist. Der Beitrag der Arbeit liegt dabei nicht nur im Nachweis der grundsätzlichen Funktionsfähigkeit, sondern vor allem in der kritischen Bewertung der Evaluationsmethoden und in der praktischen Untersuchung der Übertragbarkeit auf reale Umgebungen und kostengünstige Hardware. Die Ergebnisse machen deutlich, dass hohe Einzelmetriken aus kontrollierten Datensätzen nur eingeschränkt aussagekräftig sind und dass für eine belastbare Bewertung vor allem die Generalisierungsfähigkeit unter unbekannten Bedingungen berücksichtigt werden muss.

Für weiterführende Arbeiten ergeben sich daraus mehrere Ansatzpunkte. Dazu zählen adaptive Fenstergrößen zur besseren Kompensation schwankender Paketraten, robustere Verfahren zur Übertragung auf neue Räume ohne vollständiges Retraining sowie umfangreichere Messkampagnen mit mehr Personen, mehr Sessions und unterschiedlichen Umgebungen, um die Generalisierungsfähigkeit des Systems weiter zu verbessern.

Literatur

[1] M. T. Abdurrahman and A. Irawan. Stable human activity recognition using esp32-collected csi data with lstm-attention. In *2025 Tenth International Conference on Informatics and Computing (ICIC)*, pages 1–6, 2025.

[2] N. Damodaran, E. Haruni, M. Kokhkharova, et al. Device free human activity and fall recognition using wifi channel state information (csi). *CCF Trans. Pervasive Comp. Interact.*, 2:1–17, 2020.

[3] S. Aruna Deepthi, K. Deepthi, Keerthana Prakash, Korukonda Lakshmi Samhitha, and Bachu Anoohya. Wifi-csi based human activity recognition using esp 32. In *2025 5th IEEE International Conference on Applied Electromagnetics, Signal Processing, Communication (AESPC)*, pages 1–7, 2025.

[4] A. Elkelany, R. Ross, and S. Mckeever. Wifi-based human activity recognition using attention-based bilstm. In *Artificial Intelligence and Cognitive Science*, pages 121–133, 2022.

[5] S. M. Hernandez. Esp32-csi-tool. GitHub repository. Zugriff: 2. Februar 2026.

[6] H. Kang, J. Shin, Y. Han, and J. Choi. Human activity recognition through augmented wifi csi signals by lightweight attention-gru. *Sensors*, 25(5):1547, February 2025.

[7] M. Kotaru et al. Spotfi: Decimeter level localization using wifi. In *SIGCOMM '15*, pages 269–282, 2015.

[8] M. Lee. Gelu activation function in deep learning: A comprehensive mathematical analysis and performance. *arXiv preprint arXiv:2305.12073*, 2023.

[9] S. Tan, Y. Ren, J. Yang, and Y. Chen. Commodity wifi sensing in 10 years: Status, challenges, and opportunities. *IEEE Internet of Things Journal*, 2022. To appear.

[10] X. Wang et al. Deepfi: Deep learning for indoor fingerprinting using channel state information. In *WCNC*, pages 1666–1671, 2015.

[11] J. Xiong and K. Jamieson. Arraytrack: A fine-grained indoor location system. In *NSDI 13*, pages 71–84, 2013.

Abbildungsverzeichnis

1 Transformierung der Struktur für Standardisierung 11
2 Vergleich der Train/Test Split Ergebnisse 20
3 Group K-Fold: LSTM ohne Augmentation 21
4 Group K-Fold: LSTM mit Augmentation 22
5 Group K-Fold: CNN ohne Augmentation 23
6 Group K-Fold: CNN mit Augmentation 24
7 Gesamtvergleich von der Group K-Fold 24
8 Räumliche Beschreibung des Versuchsaufbaus und der Sensorplatzierung. 27
9 Inkonsistente Paketrate aufgrund von Umgebungsinterferenzen und Hardware-Limitierungen 29
10 Ablauf der Live-und Offline-Pipeline 29
11 Accuracy sowie Loss des Hybriden Models beim Standard Split. 35
12 Validation Loss pro Fold auf ESP-Daten 36
13 Validation Accuracy pro Fold 36